



รายงาน

การทำนายการยกเลิกการใช้บริการของลูกค้าของผู้ให้บริการโทรศัพท์มือถือ
ด้วยเทคนิคการเรียนรู้ของเครื่อง

จัดทำโดย

นายกิตติพัฒน์	วรารังสีโรจน์	รหัสนิสิต	6510401533
นายอาทิตย์	จันทร์แก้ว	รหัสนิสิต	6510402068
นายภัทรพงศ์	ชนะอาภา	รหัสนิสิต	6510401827
นางธนัทธอร	จันทร์ตัน	รหัสนิสิต	6510401690
นายอดิศักดิ์	ดัดแจ่ม	รหัสนิสิต	6510402033
นางกิตติวรินทร์	ถือศีล	รหัสนิสิต	6510401541

อาจารย์ประจำวิชา

ชื่อ ดร.ปูเป้ สุดศิลา

รายงานนี้เป็นส่วนหนึ่งของรายวิชา 01422426

ภาคต้น ปีการศึกษา 2568

ภาควิชาสถิติ คณะวิทยาศาสตร์

มหาวิทยาลัยเกษตรศาสตร์

บทคัดย่อ

ในยุคที่เทคโนโลยีสารสนเทศและการสื่อสารมีบทบาทสำคัญต่อการดำเนินชีวิตประจำวัน ธุรกิจโทรคมนาคมจึงกลายเป็นหนึ่งในอุตสาหกรรมที่มีการแข่งขันสูงและมีการเปลี่ยนแปลงอย่างรวดเร็ว ผู้ให้บริการโทรศัพท์มือถือจำเป็นต้องปรับตัวอยู่เสมอ เพื่อสร้างความพึงพอใจและรักษาความสัมพันธ์กับลูกค้าให้ยั่งยืน อย่างไรก็ตาม ปัญหาการยกเลิกการใช้บริการของลูกค้าหรือ Customer Churn ยังคงเป็นความท้าทายสำคัญที่ส่งผลต่อรายได้และความมั่นคงของธุรกิจโดยตรง

ด้วยเหตุนี้ การนำเทคโนโลยี Machine Learning เข้ามาช่วยในการวิเคราะห์และทำนาย พฤติกรรมของลูกค้าจึงเป็นแนวทางที่ได้รับความนิยมอย่างมากในปัจจุบัน เนื่องจากสามารถช่วยให้ผู้ประกอบการเข้าใจปัจจัยที่มีผลต่อการตัดสินใจยกเลิกบริการ และสามารถวางกลยุทธ์เชิงรุกเพื่อ ป้องกันการสูญเสียลูกค้าได้อย่างมีประสิทธิภาพ

โครงการฉบับนี้จัดทำขึ้นเพื่อศึกษาการประยุกต์ใช้เทคโนโลยีการเรียนรู้ของเครื่องในการ ทำนายการยกเลิกบริการของลูกค้าโทรศัพท์มือถือ โดยมุ่งหวังให้ผลลัพธ์ที่ได้สามารถนำไปใช้ ประโยชน์ในการวางแผนกลยุทธ์ด้านการตลาดและการบริการลูกค้า เพื่อเพิ่มความพึงพอใจและรักษาฐานลูกค้าเดิมขององค์กรได้ในระยะยาว

ผู้จัดทำหวังเป็นอย่างยิ่งว่าโครงการนี้จะเป็นประโยชน์ต่อผู้ที่สนใจด้านการวิเคราะห์ข้อมูลเชิงพยากรณ์ ตลอดจนผู้ประกอบการในอุตสาหกรรมโทรคมนาคมที่ต้องการพัฒนาแนวทางในการบริหารความสัมพันธ์กับลูกค้าให้มีประสิทธิภาพมากยิ่งขึ้น

สารบัญ

	หน้า
บทที่ 1 บทนำ	
1.1 ที่มาและความสำคัญ	4
1.2 วัตถุประสงค์	4
1.3 ขอบเขตการศึกษา	4
1.4 ประโยชน์ที่คาดว่าจะได้รับ	4
บทที่ 2 เอกสารและงานวิจัยที่เกี่ยวข้อง	
2.1 แนวคิดเกี่ยวกับการยกเลิกบริการของลูกค้า (Customer Churn)	5
2.2 การวิเคราะห์เชิงทำนาย	5
2.3 การเรียนรู้ของเครื่อง (Machine Learning)	5
2.4 แบบจำลองที่ใช้ในการวิเคราะห์	5
2.4.1. Decision Tree	5
2.4.2. Random Forest	6
2.4.3 XGBoost	7
บทที่ 3 วิธีการดำเนินการวิจัย	8
บทที่ 4 ผลการวิเคราะห์	10
บทที่ 5 สรุปผล อภิปรายผล และข้อเสนอแนะ	12
เอกสารอ้างอิง	13
ภาคผนวก	14

บทที่ 1 บทนำ

1.1 ที่มาและความสำคัญ

ในยุคปัจจุบัน การแข่งขันของธุรกิจโทรศัพท์มือถือในประเทศไทยมีความรุนแรงมากขึ้นอย่างต่อเนื่อง ผู้ให้บริการแต่ละรายต่างมุ่งเน้นการสร้างกลยุทธ์เพื่อดึงดูดลูกค้าใหม่ และรักษาลูกค้าเดิมให้คงอยู่กับบริษัทให้นานที่สุด อย่างไรก็ตาม หนึ่งในปัญหาหลักที่ธุรกิจโทรคมนาคมต้องเผชิญคือ “การยกเลิกการใช้บริการของลูกค้า” หรือที่เรียกว่า Customer Churn ซึ่งส่งผลโดยตรงต่อรายได้ และต้นทุนทางธุรกิจ

การเข้าใจปัจจัยที่ทำให้ลูกค้าตัดสินใจยกเลิกบริการจึงเป็นสิ่งสำคัญ เพราะช่วยให้บริษัทสามารถวางแผนกลยุทธ์เชิงรุก เช่น การมอบสิทธิพิเศษ การปรับแพ็คเกจ หรือการปรับปรุงคุณภาพ สัญญาให้ตรงตามความต้องการของลูกค้า การใช้เทคโนโลยี Machine Learning เพื่อทำนาย แนวโน้มการยกเลิกบริการจึงเป็นแนวทางที่ได้รับความนิยม เนื่องจากสามารถเรียนรู้จากข้อมูลจำนวนมากและหาความสัมพันธ์ซ่อนเร้นระหว่างตัวแปรได้อย่างมีประสิทธิภาพ

ดังนั้น โครงการนี้จึงมีวัตถุประสงค์เพื่อพัฒนาแบบจำลองการเรียนรู้ของเครื่อง เพื่อทำนายว่า ลูกค้าของผู้ให้บริการโทรศัพท์มือถือจะยกเลิกบริการหรือไม่ โดยอาศัยข้อมูลพฤติกรรมการใช้งานและ ข้อมูลส่วนบุคคลบางส่วน เพื่อช่วยให้บริษัทสามารถนำผลลัพธ์ไปใช้วางแผนกลยุทธ์ในการรักษาลูกค้า ได้อย่างเหมาะสม

1.2 วัตถุประสงค์

1. เพื่อวิเคราะห์ปัจจัยที่มีอิทธิพลต่อการยกเลิกการใช้บริการของลูกค้า
2. เพื่อสร้างแบบจำลองการทำนายการยกเลิกการใช้บริการของลูกค้าด้วยเทคนิค Machine Learning
3. เพื่อเปรียบเทียบประสิทธิภาพของแบบจำลองแต่ละชนิดและเลือกแบบจำลองที่เหมาะสม ที่สุด

1.3 ขอบเขตการศึกษา

1. ข้อมูลที่ใช้ในการวิเคราะห์เป็นข้อมูลสมมติของลูกค้าผู้ให้บริการโทรศัพท์มือถือ เช่น เพศ อายุ ระยะเวลาการเป็นลูกค้า ประเภทแพ็คเกจ จำนวนครั้งในการร้องเรียน ยอดค่าใช้จ่ายเฉลี่ยต่อ เดือน และสถานะการยกเลิกบริการ (Churn)
2. แบบจำลองที่ใช้ประกอบด้วย Decision Tree, Random Forest และ XGBoost
3. การประเมินประสิทธิภาพของโมเดลใช้ค่าความแม่นยำ (Accuracy), ค่าความถูกต้องเชิง บวก (Precision), ค่าการเรียกคืน (Recall) และค่า F1-score

1.4 ประโยชน์ที่คาดว่าจะได้รับ

1. ได้แบบจำลองที่สามารถทำนายแนวโน้มการยกเลิกบริการของลูกค้าได้อย่างแม่นยำ
2. สามารถระบุปัจจัยสำคัญที่มีผลต่อการยกเลิกบริการ เพื่อใช้ในการปรับปรุงกลยุทธ์ทาง ธุรกิจ
3. ช่วยลดอัตราการสูญเสียลูกค้า (Churn Rate) และเพิ่มประสิทธิภาพในการบริหาร ความสัมพันธ์กับลูกค้า (Customer Relationship Management)

บทที่ 2 เอกสารและงานวิจัยที่เกี่ยวข้อง

2.1 แนวคิดเกี่ยวกับการยกเลิกบริการของลูกค้า (Customer Churn) (Ahmad et al., 2019; Verbeke et al., 2014)

การยกเลิกบริการของลูกค้า (Customer Churn) หมายถึง การที่ลูกค้าหยุดใช้บริการของ บริษัท ไม่ที่จะเป็นการปิดบัญชี ยกเลิกสัญญา หรือเปลี่ยนไปใช้บริการของคู่แข่ง ซึ่งเป็นปัญหาสำคัญ ที่ส่งผลโดยตรงต่อรายได้ของธุรกิจโทรคมนาคม

2.2 การวิเคราะห์เชิงทำนาย (Predictive Analytics) (Shmueli & Koppius, 2011; Han et al., 2011)

การวิเคราะห์เชิงทำนาย (Predictive Analytics) เป็นเทคนิคที่อาศัยข้อมูลในอดีตร่วมกับ แบบจำลองทางสถิติหรือการเรียนรู้ของเครื่อง เพื่อทำนายแนวโน้มของเหตุการณ์ในอนาคตอย่างมี เหตุผลและเป็นระบบ

2.3 การเรียนรู้ของเครื่อง (Machine Learning) (Han et al., 2011)

Machine Learning คือกระบวนการที่คอมพิวเตอร์สามารถเรียนรู้จากข้อมูลเพื่อคาดการณ์ ผลลัพธ์โดยไม่ต้องเขียนกฎตายตัว โดยแบ่งออกเป็น 3 ประเภทหลัก ได้แก่ 1.) Supervised Learning เช่น การจำแนกประเภท (Classification) 2.) Unsupervised Learning เช่น การจัดกลุ่มข้อมูล (Clustering) 3.) Reinforcement Learning สำหรับการเรียนรู้จากการลองผิดลองถูก งานวิจัยนี้ใช้เทคนิค Supervised Learning เพื่อจำแนกลูกค้าว่าจะ “ยกเลิกบริการ” หรือ “ไม่ยกเลิกบริการ”

2.4 แบบจำลองที่ใช้ในการวิเคราะห์

2.4.1. Decision Tree โมเดลที่ใช้การแตกกิ่งของเงื่อนไขเพื่อจำแนกข้อมูล (Han et al., 2011)

Decision Tree หรือ ต้นไม้ตัดสินใจ เป็นเทคนิคพื้นฐานและได้รับความนิยมอย่างมากในการ จำแนกข้อมูล (Classification) และการพยากรณ์ (Prediction) เนื่องจากมีโครงสร้างที่เข้าใจง่ายและ สามารถแสดงผลในรูปแบบเชิงตรรกะได้อย่างชัดเจน (Han et al., 2011) โดยโครงสร้างของต้นไม้ ตัดสินใจประกอบด้วย โหนดราก (Root Node) ซึ่งแทนกลุ่มข้อมูลทั้งหมด, โหนดภายใน (Internal Nodes) ซึ่งใช้เงื่อนไขในการแบ่งข้อมูลตามคุณลักษณะ (Attribute), และ โหนดใบ (Leaf Nodes) ซึ่ง แสดงผลลัพธ์ของการจำแนกหรือค่าที่ทำนายได้ กระบวนการสร้างต้นไม้ตัดสินใจเริ่มจากการเลือกตัวแปรหรือคุณลักษณะที่เหมาะสมที่สุด สำหรับการแบ่งข้อมูลในแต่ละขั้นตอน โดยใช้เกณฑ์การวัดความบริสุทธิ์ของกลุ่มข้อมูล (Impurity Measure) เช่น Information Gain, Gain Ratio, หรือ Gini Index เพื่อประเมินว่าการแบ่งด้วยตัวแปรใดทำให้ข้อมูลภายในกลุ่มมีความคล้ายคลึงกันมากที่สุด จากนั้นทำการแบ่งข้อมูลซ้ำ ๆ (Recursive Partitioning) จนกว่าจะได้โหนดที่มีข้อมูลบริสุทธิ์ หรือไม่สามารถแบ่งเพิ่มเติมได้อีก

นอกจากนี้ Han et al. (2011) ยังกล่าวถึงกระบวนการ Pruning หรือการตัดแต่งต้นไม้ เพื่อ ป้องกันปัญหา Overfitting ที่เกิดจากการเรียนรู้รายละเอียดมากเกินไปในข้อมูลฝึก (Training Data) โดยจะทำการตัด

บางส่วนของต้นไม้ถูกทำให้โมเดลมีความทั่วไป (Generalization) มากขึ้น และสามารถทำนายข้อมูลใหม่ได้แม่นยำกว่า ต้นไม้ตัดสินใจสามารถประยุกต์ใช้ได้ทั้งในงานจำแนกประเภท (Classification) และงานพยากรณ์เชิงตัวเลข (Regression) โดยในกรณีหลังจะเรียกว่า Regression Tree ซึ่งใช้ค่าเฉลี่ยของ ข้อมูลในแต่ละกลุ่มเป็นผลลัพธ์การทำนาย ทั้งนี้ จุดเด่นของเทคนิคนี้คือความสามารถในการตีความได้ ง่าย ไม่จำเป็นต้องใช้สมการเชิงคณิตศาสตร์ที่ซับซ้อน และสามารถจัดการกับข้อมูลเชิงตัวเลขและเชิง กลุ่มได้พร้อมกัน

ในภาพรวม Decision Tree ถือเป็นรากฐานสำคัญของเทคนิคการเรียนรู้ของเครื่องแบบเชิง Ensemble หลายวิธี เช่น Random Forest และ Gradient Boosting, ซึ่งต่างก็พัฒนาต่อยอดจาก แนวคิดของการรวมต้นไม้ตัดสินใจหลายต้นเข้าด้วยกันเพื่อเพิ่มความแม่นยำในการทำนาย

2.4.2. Random Forest การรวมผลของหลายต้นไม้ตัดสินใจเพื่อลดความลำเอียง

Random Forest เป็นการพัฒนาต่อยอดจากเทคนิค Bagging หรือ Bootstrap Aggregating โดยมีจุดเด่นคือการสร้างต้นไม้ตัดสินใจ ที่มีความไม่สัมพันธ์กัน เพื่อลดความแปรปรวน (variance) ของ แบบจำลองได้ดีกว่า Bagging แบบเดิม Random Forest ทำงานโดยการฝึกต้นไม้จำนวนมากบนชุด ข้อมูลที่ได้จากการสุ่มซ้ำแบบ bootstrap แล้วรวมผลลัพธ์ของต้นไม้ทั้งหมดผ่านการเฉลี่ย (ในกรณี regression) หรือการโหวตเสียงข้างมาก (ในกรณี classification) วิธีนี้ช่วยลดความเอนเอียง (bias) และเพิ่มความสามารถในการทั่วไป (generalization ability) ของแบบจำลองเทคนิคนี้มีข้อดีที่สำคัญ ได้แก่ ลดความแปรปรวน (variance) ได้มากกว่าการใช้ Bagging เพียงอย่างเดียว ให้ผลการทำนายที่มีความแม่นยำใกล้เคียงกับ Boosting ในหลายบริบท และมีความง่ายในการฝึกสอน (training) และการปรับแต่งค่าพารามิเตอร์ เมื่อ เปรียบเทียบกับวิธีการ ensemble อื่น ๆ ด้วยคุณสมบัติเหล่านี้ Random Forest จึงได้รับความนิยมอย่างแพร่หลายในงาน ด้านการจำแนกประเภท (classification) และการพยากรณ์ (regression) โดยเฉพาะในกรณีที่ ต้องการสมดุลระหว่างความแม่นยำและความง่ายในการใช้งาน นิยามของ Random Forest ขั้นตอน การฝึก (Training Phase)

ทำซ้ำขั้นตอนต่อไปนี้สำหรับ $b = 1, 2, 3, \dots, B$ (จำนวนต้นไม้ทั้งหมด) (The Elements of Statistical, 2001) Learning Data Mining, Inference

1. สุ่มข้อมูลฝึกแบบ Bootstrap สุ่มตัวอย่างซ้ำ (bootstrap sample) ขนาด N จากชุดข้อมูลฝึกเดิม เพื่อสร้างชุดข้อมูลฝึกใหม่ z^* สร้างต้นไม้ T_b โดยใช้ z^*
2. ที่แต่ละโหนด ให้สุ่มเลือกตัวแปรจำนวน m ตัว จากตัวแปรทั้งหมด p ตัว (โดยปกติ $m < p$) จาก m ตัวแปรที่สุ่มได้ เลือกตัวแปรและจุดแบ่งที่เหมาะสมที่สุดโดยพิจารณา เกณฑ์เช่น Gini (ในกรณี classification) หรือ SSE (ในกรณี regression) แบ่งโหนดออกเป็นสอง โหนดย่อย และทำซ้ำกระบวนการนี้จนกว่าจะถึงเงื่อนไขหยุด (เช่น ขนาดโหนดเล็กกว่าค่าที่กำหนด)
3. ขั้นตอนการทำนาย (Prediction Phase): เมื่อได้ต้นไม้ทั้งหมด $T_1, T_2, \dots$ แล้วสำหรับอินพุตใหม่ x

RandomForestเป็นเทคนิคที่ช่วยลดความแปรปรวนของแบบจำลองได้อย่างมีประสิทธิภาพ ผ่านการเฉลี่ยผลลัพธ์จากต้นไม้จำนวนมาก การลดค่าความสัมพันธ์ระหว่างต้นไม้ จะช่วยลดความแปรปรวน ของผลเฉลี่ยของแบบจำลอง ส่งผลให้ Random Forest มีความสามารถในการทั่วไป (generalization) ที่ดีขึ้นตัวประมาณค่าจำกัดของ Random Forest

2.4.3 XGBoost – แบบจำลองแบบ Gradient Boosting ที่มีประสิทธิภาพสูงในการจำแนกข้อมูลไม่สมดุล (Chen & Guestrin, 2016)

XGBoost หรือ Extreme Gradient Boosting เป็นแบบจำลองการเรียนรู้ของเครื่องที่ได้รับการพัฒนาต่อยอดจากแนวคิดของ Gradient Boosting ซึ่งมีพื้นฐานจากเทคนิคการรวมแบบจำลองหลาย ตัวเข้าด้วยกัน (Ensemble Learning) โดยเฉพาะการรวม Decision Tree หลายต้นเข้าด้วยกันใน ลักษณะต่อเนื่อง (Sequential) เพื่อปรับปรุงความแม่นยำของการทำนาย แนวคิดหลักของ XGBoost คือการสร้างต้นไม้ตัดสินใจต้นใหม่ในแต่ละรอบ เพื่อแก้ไขข้อผิดพลาดของต้นไม้ก่อนหน้า โดยใช้ หลักการของ Gradient Descent Optimization ในการลดค่าความสูญเสีย (Loss Function) ทีละ ขั้นอย่างมีประสิทธิภาพ แบบจำลองจะเรียนรู้จาก Residuals หรือค่าความคลาดเคลื่อนของการ ทำนายเดิม แล้วค่อย ๆ ปรับน้ำหนักของต้นไม้ในรอบถัดไปให้สามารถทำนายข้อมูลที่ยากขึ้นได้ดีขึ้น

XGBoost ได้รับการออกแบบให้ทำงานได้อย่างมีประสิทธิภาพในแง่ของ ความเร็ว (Speed), ความแม่นยำ (Accuracy) และ การป้องกันการเกิด Overfitting โดยมีการเพิ่มกระบวนการ Regularization (L1 และ L2 Penalty) เพื่อควบคุมความซับซ้อนของโมเดล และช่วยให้ผลลัพธ์มี ความทั่วไปมากขึ้น (Generalization) อีกทั้งยังสามารถทำงานแบบขนาน (Parallel Processing) และใช้หน่วยความจำอย่างมีประสิทธิภาพ ทำให้เหมาะสำหรับข้อมูลขนาดใหญ่และข้อมูลที่ไม่สมดุล สำหรับปัญหาการจำแนกข้อมูลไม่สมดุล (Imbalanced Classification) XGBoost สามารถปรับ น้ำหนักของกลุ่มตัวอย่างในแต่ละคลาส (Class Weighting) ได้โดยใช้พารามิเตอร์ scale_pos_weight เพื่อเพิ่มน้ำหนักให้กับคลาสที่มีจำนวนน้อยกว่า ส่งผลให้โมเดลให้ความสำคัญกับ กลุ่มข้อมูลขนาดเล็กมากขึ้น และลดปัญหาการลำเอียงไปยังคลาสที่มีจำนวนมากกว่า นอกจากนี้ยัง สามารถใช้ร่วมกับเทคนิคปรับสมดุลข้อมูล เช่น SMOTE หรือ Tomek Links เพื่อเพิ่มประสิทธิภาพ การจำแนกได้อีกด้วย

ด้วยคุณสมบัติดังกล่าว XGBoost จึงได้รับความนิยมอย่างแพร่หลายในการแก้ปัญหาจำแนกข้อมูล โดยเฉพาะในกรณีที่ข้อมูลมีขนาดใหญ่หรือไม่สมดุล เช่น การวิเคราะห์พฤติกรรมลูกค้า การตรวจจับ การทุจริตทางการเงิน และการทำนายการยกเลิกบริการของลูกค้า (Customer Churn Prediction) ซึ่งโมเดลสามารถให้ผลการทำนายที่แม่นยำและเสถียรมากกว่าวิธีการแบบดั้งเดิม

บทที่ 3 วิธีการดำเนินการวิจัย

3.1 กระบวนการดำเนินงานโดยรวมประกอบด้วยขั้นตอน ดังนี้

1. การเก็บรวบรวมข้อมูลลูกค้า
2. การเตรียมและทำความสะอาดข้อมูล
3. การเลือกตัวแปรที่สำคัญ
4. การสร้างแบบจำลองด้วยเทคนิค Machine Learning
5. การประเมินผลและเลือกแบบจำลองที่ดีที่สุด

3.2 ข้อมูลที่ใช้ในการวิเคราะห์

ข้อมูลประกอบด้วยลูกค้าทั้งหมด 5,000 ราย จากผู้ให้บริการโทรศัพท์มือถือแห่งหนึ่ง โดยมีตัวแปรหลัก ได้แก่ ตัวแปรเชิงคุณภาพและตัวแปรเชิงปริมาณ

3.2.1. ตัวแปรเชิงคุณภาพ

Gender (เพศ) กำหนด Female 0 Male 1

partner (มีคู่สมรสหรือไม่) กำหนด Yes 1 No 0

Dependents (มีผู้พึ่งพิงหรือไม่) กำหนด Yes 1 No 0

PhoneService (ใช้บริการโทรศัพท์หรือไม่) กำหนด Yes 1 No 0

PaperlessBilling (การเรียกเก็บเงินแบบไม่ใช้กระดาษ) กำหนด Yes 1 No 0

MultipleLines (มีหลายสายโทรศัพท์หรือไม่) กำหนด Yes 0 No 1 No phone service 2

InternetService (ประเภทของบริการอินเทอร์เน็ต) กำหนด Yes 0 No 1 No phone service 2

OnlineSecurity(ใช้บริการรักษาความปลอดภัยออนไลน์หรือไม่) กำหนด Yes 0 No 1 No phone service 2

DeviceProtection (ใช้บริการประกันอุปกรณ์หรือไม่) กำหนด Yes 0 No 1 No phone service 2

TechSupport (ใช้บริการช่วยเหลือด้านเทคนิคหรือไม่) กำหนด Yes 0 No 1 No phone service 2

StreamingTV (ใช้บริการสตรีมมิงทีวีหรือไม่) กำหนด Yes 0 No 1 No phone service 2

StreamingMovies (ใช้บริการสตรีมมิงภาพยนตร์หรือไม่) กำหนด Yes 0 No 1 No phone service 2

3.2.1. ตัวแปรเชิงปริมาณ Tenure (ระยะเวลาการเป็นลูกค้า)

MonthlyCharges (ค่าใช้จ่ายรายเดือน)

TotalCharges (ยอดค่าใช้จ่ายรวมทั้งหมด)

3.3 การเตรียมข้อมูล

ดำเนินการจัดการค่าที่หาย (Missing Values) การเข้ารหัสตัวแปรเชิงหมวดหมู่ (One-Hot Encoding) และการปรับสเกลข้อมูลเชิงตัวเลข (Standardization)

3.4 การสร้างแบบจำลอง

ได้ทำการทดลองสร้างแบบจำลอง Machine Learning 3 แบบ คือ Decision Tree Random Forest และ XGBoost

3.5 การประเมินผลแบบจำลอง

ใช้วิธี Train-Test Split (80:20) และประเมินประสิทธิภาพด้วย ค่าความถูกต้อง (Accuracy) ค่าความแม่นยำ (Precision) ค่าการเรียกคืน (Recall) และ คะแนน F1 (F1-score) โดยเลือก แบบจำลองที่มีค่า F1-score สูงสุดเป็นโมเดลที่ดีที่สุด

บทที่ 4 ผลการวิเคราะห์

4.1 สถิติพื้นฐานของข้อมูล

ข้อมูลลูกค้าที่ใช้ในการศึกษานี้เป็นข้อมูลสมมติจากบริษัทผู้ให้บริการโทรศัพท์มือถือ ประกอบด้วยข้อมูลลูกค้าจำนวน 5,000 ตัวอย่าง ครอบคลุมตัวแปรสำคัญ เช่น อายุ ระยะเวลาการใช้ บริการ รายได้ต่อเดือน จำนวนครั้งที่ติดต่อศูนย์บริการ ประเภทแพ็คเกจที่ใช้ และสถานะการยกเลิกบริการ (Churn) ซึ่งเป็นตัวแปรตาม (Dependent Variable) ในการวิเคราะห์

4.2 การแบ่งชุดข้อมูล

ข้อมูลทั้งหมดถูกแบ่งออกเป็น 2 ชุด ได้แก่ ชุดฝึกสอน (Training set) ร้อยละ 80 และ ชุด ทดสอบ (Testing set) ร้อยละ 20 เพื่อใช้ในการสร้างและทดสอบประสิทธิภาพของโมเดล Machine Learning

4.3 แบบจำลองที่ใช้ในการวิเคราะห์

ได้ทำการเปรียบเทียบผลลัพธ์ของแบบจำลอง 3 ประเภท ได้แก่ Decision Tree Random Forest และ XGBoost

4.4 ผลการประเมินประสิทธิภาพของโมเดล

แสดงดังตารางที่ 4.4.1

โมเดล	Accuracy	Precision	Recall	F1-score
Decision Tree	0.7516	0.6791	0.6721	0.6753
Random Forest	0.7928	0.7396	0.6882	0.7048
XGBoost	0.7999	0.7471	0.7092	0.7233

จากตารางที่ 4.4.1 แสดงผลการประเมินประสิทธิภาพของแบบจำลองการจำแนกข้อมูล 3 รูปแบบ ได้แก่ Decision Tree, Random Forest, และ XGBoost โดยใช้ตัวชี้วัดหลัก 4 ค่า ได้แก่ Accuracy, Precision, Recall, และ F1-score เพื่อเปรียบเทียบความสามารถของแต่ละโมเดลในการทำนายการ ยกเลิกบริการของลูกค้า (Customer Churn) ผลการวิเคราะห์พบว่าแบบจำลอง XGBoost ให้ค่าประสิทธิภาพสูงสุดในทุกตัวชี้วัด โดยมีค่า Accuracy เท่ากับ 0.7999, Precision เท่ากับ 0.7471, Recall เท่ากับ 0.7092, และ F1-score เท่ากับ 0.7233 แสดงให้เห็นว่า XGBoost สามารถจำแนก กลุ่มลูกค้าที่มีแนวโน้มจะยกเลิกบริการได้อย่างแม่นยำและสมดุลระหว่างความถูกต้องของการทำนาย และความครอบคลุมของข้อมูลที่แท้จริง ขณะที่แบบจำลอง Random Forest มีประสิทธิภาพ รองลงมา โดยมีค่า Accuracy เท่ากับ 0.7928 และ F1-score เท่ากับ 0.7048 แสดงถึงความสามารถ ในการจำแนกได้ดีพอสมควร แต่ยังมีการทำนายผิดพลาดบางส่วน โดยเฉพาะในกรณีข้อมูลที่ไม่สมดุล ส่วน แบบจำลอง Decision Tree ให้ค่าประสิทธิภาพต่ำสุด (Accuracy เท่ากับ 0.7516 และ F1-score เท่ากับ 0.6753) ซึ่งสอดคล้องกับลักษณะของโมเดลที่มีแนวโน้มเกิด Overfitting ได้ง่าย และไม่สามารถจับความสัมพันธ์เชิงซับซ้อนของข้อมูลได้ดีเท่าแบบจำลอง Ensemble อื่น ๆ โดยสรุป

แบบจำลอง XGBoost แสดงประสิทธิภาพดีที่สุดในการจำแนกกลุ่มลูกค้าที่มีแนวโน้มจะยกเลิกบริการ ซึ่งแสดงให้เห็นถึงศักยภาพของเทคนิค Gradient Boosting ในการจัดการกับข้อมูลที่ซับซ้อนและไม่ สมดุลได้อย่างมีประสิทธิภาพมากกว่าแบบจำลองอื่น ๆ ที่ใช้ในการศึกษา

4.5 การวิเคราะห์ผลลัพธ์

จากตารางพบว่า โมเดล XGBoost มีค่า Accuracy สูงที่สุดที่ 0.7999 รวมถึงมีค่า Precision, Recall และ F1-score ที่สูงกว่าแบบจำลองอื่น ๆ ซึ่งแสดงให้เห็นว่าโมเดล XGBoost สามารถทำนาย การยกเลิกบริการของลูกค้าได้แม่นยำกว่าทั้ง Decision Tree และ Random Forest โดยโมเดล Random Forest ก็ยังคงมีประสิทธิภาพดีและให้ค่าความถูกต้องใกล้เคียงกัน ส่วน Decision Tree มีความแม่นยำต่ำสุด ซึ่งอาจเกิดจากการ Overfitting หรือการแบ่งโหนดที่ซับซ้อนเกินไปในบางกรณี

4.6 การตีความตัวแปรสำคัญ (Feature Importance)

จากการวิเคราะห์ด้วยโมเดล Random Forest และ XGBoost พบว่า ตัวแปรที่มีอิทธิพลต่อ การยกเลิกบริการมากที่สุด ได้แก่ ระยะเวลาการเป็นลูกค้า (Tenure) จำนวนครั้งที่ติดต่อศูนย์บริการ (Customer Service Calls) ค่าใช้จ่ายรายเดือน (Monthly Charges) ประเภทแพ็คเกจบริการ (Plan Type) โดยลูกค้าที่ติดต่อศูนย์บริการบ่อยและมีค่าใช้จ่ายรายเดือนสูง มีแนวโน้มที่จะยกเลิกการใช้บริการมากกว่าลูกค้ากลุ่มอื่น

บทที่ 5 สรุปผล อภิปรายผล และข้อเสนอแนะ

5.1 สรุปผลการวิจัย

จากการศึกษาการทำนายการยกเลิกการใช้บริการของลูกค้า (Customer Churn) ของบริษัท ผู้ให้บริการโทรศัพท์มือถือ โดยประยุกต์ใช้เทคนิคการเรียนรู้ของเครื่อง (Machine Learning) ได้แก่ Decision Tree, Random Forest และ XGBoost พบว่าแบบจำลอง XGBoost ให้ประสิทธิภาพสูงที่สุด โดยมีค่า Accuracy เท่ากับ 0.7999 และค่า F1-score เท่ากับ 0.7233 ซึ่งสูงกว่าแบบจำลองอื่น ทั้งในด้านความถูกต้องและความสมดุลระหว่าง Precision และ Recall

ผลการวิจัยแสดงให้เห็นว่า XGBoost สามารถจัดการกับความไม่สมดุลของข้อมูลและความซับซ้อนของความสัมพันธ์ระหว่างตัวแปรได้ดีกว่าแบบจำลองเชิงต้นไม้ทั่วไป เช่น Decision Tree และ Random Forest จึงเหมาะสมในการนำไปใช้เป็นแบบจำลองหลักในการทำนายการยกเลิกบริการ ของลูกค้า เพื่อช่วยให้ธุรกิจสามารถคาดการณ์และวางแผนกลยุทธ์ในการรักษาลูกค้าได้อย่างมีประสิทธิภาพมากขึ้น

5.2 การอภิปรายผล

ผลการวิเคราะห์แสดงให้เห็นว่า การใช้เทคนิค Machine Learning สามารถช่วยให้ธุรกิจ โทรศัพท์มือถือคาดการณ์พฤติกรรมการยกเลิกบริการได้อย่างมีประสิทธิภาพ โดยโมเดล XGBoost ให้ ผลลัพธ์ที่ดีกว่าเนื่องจากการปรับน้ำหนักของตัวแปรและลดข้อผิดพลาดแบบ iterative ทำให้ได้ผล แม่นยำและมีการ Generalize ดีกว่าโมเดลต้นไม้มากกว่า นอกจากนี้ยังพบว่าตัวแปร Tenure และ Customer Service Calls มีอิทธิพลต่อการยกเลิกบริการมาก ซึ่งสอดคล้องกับงานวิจัยใน ต่างประเทศหลายชิ้นที่พบว่าลูกค้าที่อยู่กับ บริษัทในระยะสั้น และติดต่อฝ่ายบริการลูกค้าบ่อย มักมี แนวโน้มจะยกเลิกการใช้บริการสูง

5.3 ข้อจำกัดของการวิจัย

ข้อมูลที่ใช้เป็นข้อมูลสมมติ ไม่ได้มาจากลูกค้าจริง อาจไม่สะท้อนพฤติกรรมในสถานการณ์จริง ไม่ได้พิจารณาปัจจัยเชิงจิตวิทยาหรือพฤติกรรม เช่น ความพึงพอใจต่อบริการ หรือการรับรู้ คุณภาพ ใช้เพียง 3 แบบจำลองเท่านั้น อาจยังไม่ครอบคลุมเทคนิค Machine Learning อื่น ๆ เช่น Neural Networks หรือ SVM 5.4 ข้อเสนอแนะสำหรับการศึกษารั้งต่อไป 1. ควรนำข้อมูลจริงจากระบบ CRM ของบริษัทมาวิเคราะห์ เพื่อเพิ่มความน่าเชื่อถือของ ผลลัพธ์ 2. ควรเพิ่มตัวแปรด้านพฤติกรรมและความคิดเห็นของลูกค้า เช่น ผลการสำรวจความพึงพอใจ หรือข้อมูลจากโซเชียลมีเดีย 3. ศึกษาการใช้เทคนิค Deep Learning หรือโมเดล Ensemble อื่น ๆ เพื่อเปรียบเทียบ ประสิทธิภาพเพิ่มเติม

เอกสารอ้างอิง

- Breiman, L. 2001. Random forests. **Machine Learning**, 45, 5–32.
- Han, J., et al. 2011. **Data Mining: Concepts and Techniques**. 3rd edition. The Morgan Kaufmann Series in Data Management Systems. Morgan Kaufmann: Waltham.
- Chen, T., & Guestrin, C. (2016). **XGBoost: A Scalable Tree Boosting System**. Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 785–794.
- Shmueli, G., & Koppius, O. R. (2011). **Predictive analytics in information systems research**. MIS Quarterly, 35(3), 553–572.
- Waller, M. A., & Fawcett, S. E. (2013). **Data science, predictive analytics, and big data: a revolution that will transform supply chain design and management**. Journal of Business Logistics, 34(2), 77–84.

ภาคผนวก

```
import warnings
warnings.filterwarnings("ignore")

import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import OneHotEncoder, LabelEncoder
from sklearn.compose import ColumnTransformer
from sklearn.impute import SimpleImputer
from sklearn.pipeline import Pipeline
from sklearn.metrics import accuracy_score, precision_score, recall_score,
f1_score
from sklearn.tree import DecisionTreeClassifier
from sklearn.ensemble import RandomForestClassifier
from xgboost import XGBClassifier

# ===== โหลดไฟล์ =====
FILE = "/content/Big data csv.csv"
df = pd.read_csv(FILE, encoding="utf-8-sig")

# ===== ระบุคอลัมน์ =====
target = "Churn"
y = LabelEncoder().fit_transform(df[target].astype(str).fillna("MISSING"))
X = df.drop(columns=[target])

# ===== แยกประเภทตัวแปร =====
num_cols = X.select_dtypes(include=['int64', 'float64']).columns.tolist()
cat_cols = X.select_dtypes(include=['object']).columns.tolist()

# ===== Preprocessing =====
✓ preprocess = ColumnTransformer([
    ("num", SimpleImputer(strategy="median"), num_cols),
    ("cat", Pipeline([
        ("imp", SimpleImputer(strategy="most_frequent")),
        ("ohe", OneHotEncoder(handle_unknown="ignore"))
    ]), cat_cols)
])

# ===== แบ่ง Train-Test =====
✓ X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42, stratify=y
```

```

# ===== โมเดล =====
models = {
    "Decision Tree": DecisionTreeClassifier(random_state=42),
    "Random Forest": RandomForestClassifier(n_estimators=200, random_state=42),
    "XGBoost": XGBClassifier(
        n_estimators=200,
        max_depth=4,
        learning_rate=0.05,
        eval_metric="mlogloss",
        random_state=42
    )
}

# ===== Train และ Evaluate =====
for name, model in models.items():
    pipe = Pipeline([("pre", preprocess), ("model", model)])
    pipe.fit(X_train, y_train)
    y_pred = pipe.predict(X_test)

    acc = accuracy_score(y_test, y_pred)
    prec = precision_score(y_test, y_pred, average='macro')
    rec = recall_score(y_test, y_pred, average='macro')
    f1 = f1_score(y_test, y_pred, average='macro')

    print(f"\n=== {name} ===")
    print(f"Accuracy: {acc:.4f}")
    print(f"Precision (macro): {prec:.4f}")
    print(f"Recall (macro): {rec:.4f}")
    print(f"F1-score (macro): {f1:.4f}")

```