



การทำนายสถานการณ์มีงานทำจากผลการเรียนและประสบการณ์ฝึกงาน
โดยใช้แบบจำลองมาร์คอฟเชนแบบดูดกลืน

จัดทำโดย

นางสาว	กานต์พิชชา	ชะม้ายกลาง	6510401509
นาย	กิติพัฒน์	วรารังสีโรจน์	6510401533
นางสาว	โชติกา	เกื้อบุญส่ง	6510401622

ภายใต้การควบคุมของ
ผศ.ดร.เสาวภา ชัยพิทักษ์

รายงานนี้เป็นส่วนหนึ่งของวิชา 01422485 การวิจัยดำเนินงานสโตนแคสติง
ภาคปลาย ปีการศึกษา 2568
ภาควิชาสถิติ คณะวิทยาศาสตร์
มหาวิทยาลัยเกษตรศาสตร์

บทคัดย่อ

การศึกษาครั้งนี้มีวัตถุประสงค์เพื่อวิเคราะห์ความสัมพันธ์ระหว่างผลการเรียนเฉลี่ยสะสม (Cumulative Grade Point Average: CGPA) และประสบการณ์การฝึกงาน (Internships) กับ สถานะการมีงานทำของนักศึกษา โดยใช้แบบจำลองมาร์คอฟเชนแบบดูดกลืน (Absorbing Markov Chain) เป็นเครื่องมือในการวิเคราะห์ข้อมูล

ข้อมูลที่ใช้ในการศึกษาเป็นข้อมูลหัตถ์ภูมิ ซึ่งประกอบด้วยตัวแปร CGPA จำนวนการฝึกงาน และ สถานะการมีงานทำ โดยมีการจัดกลุ่ม CGPA ออกเป็น 4 ระดับ ได้แก่ Excellent, Good, Average และ Low และจัดกลุ่มประสบการณ์การฝึกงานเป็น 2 ระดับ ได้แก่ High และ Low จากนั้นนำมาสร้างสถานะ (State) และคำนวณความน่าจะเป็นของการเข้าสู่สถานะการมีงานทำ (Employed) และไม่มีการมีงานทำ (Unemployed) ด้วยโปรแกรม Microsoft Excel โดยใช้ Pivot Table

ผลการศึกษาพบว่า นักศึกษาที่มีผลการเรียนในระดับ Excellent และมีประสบการณ์การฝึกงาน ในระดับสูง มีโอกาสได้งานมากที่สุด ในขณะที่นักศึกษาที่มีผลการเรียนในระดับต่ำและมีประสบการณ์การ ฝึกงานต่ำมีโอกาสดังงานน้อยที่สุด นอกจากนี้ยังพบว่าประสบการณ์การฝึกงานมีบทบาทสำคัญในการเพิ่ม โอกาสในการได้งาน แม้ในกลุ่มนักศึกษาที่มีผลการเรียนในระดับปานกลาง

จากผลการศึกษาสามารถสรุปได้ว่า ทั้งผลการเรียนและประสบการณ์การฝึกงานเป็นปัจจัยสำคัญ ที่ส่งผลต่อโอกาสในการมีงานทำของนักศึกษา และการนำแบบจำลองมาร์คอฟเชนแบบดูดกลืนมา ประยุกต์ใช้สามารถช่วยอธิบายและวิเคราะห์ความน่าจะเป็นของสถานะการมีงานทำได้อย่างมี ประสิทธิภาพ

กิตติกรรมประกาศ

รายงานฉบับนี้สำเร็จลุล่วงไปได้ด้วยดี เนื่องจากได้รับความกรุณาและความช่วยเหลือจากหลายฝ่าย ผู้จัดทำขอกราบขอบพระคุณอาจารย์ผู้สอน ที่ได้ให้คำแนะนำ แนวทาง และข้อเสนอแนะที่เป็นประโยชน์ตลอดระยะเวลาในการดำเนินงาน ทำให้รายงานฉบับนี้สมบูรณ์ยิ่งขึ้น ขอขอบคุณเพื่อน ๆ ที่ให้ความช่วยเหลือและคำแนะนำในการจัดทำรายงาน รวมถึงให้กำลังใจในการทำงานมาโดยตลอด สุดท้ายนี้ ผู้จัดทำขอขอบคุณครอบครัวที่ให้การสนับสนุนทั้งด้านกำลังใจและการช่วยเหลือในทุก ๆ ด้าน จนทำให้รายงานฉบับนี้สำเร็จลุล่วงไปได้ด้วยดี ผู้จัดทำหวังเป็นอย่างยิ่งว่ารายงานฉบับนี้จะเป็นประโยชน์ต่อผู้ที่สนใจ และหากมีข้อผิดพลาดประการใด ผู้จัดทำขออภัยไว้ ณ ที่นี้

สารบัญ

	หน้า
สารบัญ	3
สารบัญตาราง	4
สารบัญภาพ	5
บทที่ 1 บทนำ	6
1.1 ที่มาและความสำคัญ	6
1.2 วัตถุประสงค์	6
1.3 สถานที่และระยะเวลาทำรายงาน	6
1.4 ประโยชน์ที่คาดว่าจะได้รับ	7
บทที่ 2 เอกสารและงานวิจัยที่เกี่ยวข้อง	8
2.1 แนวคิดเกี่ยวกับการวิเคราะห์ข้อมูล	8
2.2 ทฤษฎีความน่าจะเป็น	8
2.3 แนวคิดเกี่ยวกับโซ่มาร์คอฟ	9
2.4 โซ่มาร์คอฟแบบดูดกลืน	9
2.5 งานวิจัยที่เกี่ยวข้อง	10
บทที่ 3 อุปกรณ์และวิธีการ	12
3.1 อุปกรณ์	12
3.2 วิธีการ	13
บทที่ 4 ผลและวิจารณ์	15
4.1 ผล	15
4.2 วิจารณ์	16
4.3 การวิจารณ์ผล	16
บทที่ 5 สรุปและข้อเสนอแนะ	18
5.1 สรุป	18
5.2 ข้อเสนอแนะ	19
เอกสารอ้างอิง	20

สารบัญตาราง

หน้า

ตารางที่ 4.1 ความน่าจะเป็นของการมีงานทำและไม่มีงานทำในแต่ละสถานะ	15
--	----

สารบัญภาพ

หน้า

รูปที่ 4.1 กราฟแท่งแสดงความน่าจะเป็นของการมีงานทำในแต่ละสถานะ

16

บทที่ 1 บทนำ

1.1 ความสำคัญ

ในปัจจุบัน การแข่งขันในการเข้าสู่ตลาดแรงงานมีแนวโน้มสูงขึ้นอย่างต่อเนื่อง นักศึกษาที่กำลังจะสำเร็จการศึกษาจำเป็นต้องมีความพร้อมทั้งด้านความรู้ทางวิชาการและทักษะที่เกี่ยวข้องกับการทำงาน เพื่อเพิ่มโอกาสในการได้รับการจ้างงาน ปัจจัยสำคัญที่มักถูกนำมาใช้พิจารณา ได้แก่ ผลการเรียนเฉลี่ยสะสม (Cumulative Grade Point Average: CGPA) และประสบการณ์การฝึกงาน (Internships) ซึ่งสะท้อนถึงศักยภาพและความพร้อมของนักศึกษาในมิติต่าง ๆ

อย่างไรก็ตาม ความสัมพันธ์ระหว่างผลการเรียน ประสบการณ์ฝึกงาน และโอกาสในการมีงานทำ ยังคงเป็นประเด็นที่ควรได้รับการศึกษาอย่างเป็นระบบ โดยการวิเคราะห์ข้อมูลเชิงปริมาณสามารถช่วยให้เข้าใจแนวโน้มและรูปแบบของโอกาสในการได้งานได้อย่างชัดเจนมากขึ้น

ในการศึกษานี้ ได้มีการนำแนวคิดของแบบจำลองมาร์คอฟ (Markov Chain) โดยเฉพาะแบบจำลอง Absorbing Markov Chain มาประยุกต์ใช้ โดยใช้การเปลี่ยนสถานะแบบ one-step transition เนื่องจากข้อมูลไม่มีลำดับเวลา เพื่อวิเคราะห์ความน่าจะเป็นที่นักศึกษาซึ่งมีลักษณะแตกต่างกันในด้านผลการเรียนและประสบการณ์ฝึกงาน จะเข้าสู่สถานะการมีงานทำ (Employed) หรือไม่มีงานทำ (Unemployed) ซึ่งจะช่วยให้สามารถอธิบายและคาดการณ์แนวโน้มของการมีงานทำได้อย่างมีหลักการและเป็นระบบ

1.2 วัตถุประสงค์

1. เพื่อศึกษาความสัมพันธ์ระหว่างผลการเรียนเฉลี่ยสะสมกับสถานะการมีงานทำ
2. เพื่อวิเคราะห์ผลของจำนวนการฝึกงานต่อโอกาสการได้งาน
3. เพื่อสร้างแบบจำลอง Absorbing Markov Chain สำหรับทำนายสถานะการมีงานทำ

1.3 สถานที่และระยะเวลาทำรายงาน

การศึกษานี้ดำเนินการโดยใช้ข้อมูลทุติยภูมิ (Secondary Data) และทำการวิเคราะห์ข้อมูลด้วยโปรแกรม Microsoft Excel ซึ่งดำเนินการโดยผู้จัดทำ

การดำเนินงานเริ่มตั้งแต่เดือนกุมภาพันธ์ ถึงเดือนมีนาคม รวมระยะเวลา 8 สัปดาห์ โดยมีขั้นตอนประกอบด้วย การค้นคว้าข้อมูล การเตรียมข้อมูล การวิเคราะห์ข้อมูล และการจัดทำรายงาน

1.4 ประโยชน์ที่คาดว่าจะได้รับ

1. ทำให้เข้าใจปัจจัยที่ส่งผลต่อโอกาสในการมีงานทำของนักศึกษาได้ชัดเจนยิ่งขึ้น
2. สามารถใช้ผลการวิเคราะห์เป็นแนวทางในการวางแผนพัฒนาตนเองของนักศึกษา
3. เป็นแนวทางสำหรับสถาบันการศึกษาในการส่งเสริมกิจกรรมหรือหลักสูตรที่ช่วยเพิ่มโอกาสในการได้งาน
4. เป็นตัวอย่างการประยุกต์ใช้แบบจำลองทางคณิตศาสตร์ในการวิเคราะห์ข้อมูลด้านการศึกษา

บทที่ 2 เอกสารที่เกี่ยวข้อง

บทนี้เป็นการรวบรวมแนวคิด ทฤษฎี และงานวิจัยที่เกี่ยวข้องกับการศึกษาครั้งนี้ โดยครอบคลุมเนื้อหาด้านการวิเคราะห์ข้อมูล ทฤษฎีความน่าจะเป็น และแบบจำลองมาร์คอฟ (Markov Chain) รวมถึงแนวคิดของ Absorbing Markov Chain ซึ่งถูกนำมาใช้ในการวิเคราะห์ความน่าจะเป็นของการมีงานทำของนักศึกษา นอกจากนี้ยังกล่าวถึงปัจจัยที่มีผลต่อการได้งาน เช่น ผลการเรียนรู้เฉลี่ยสะสมและประสบการณ์การฝึกงาน เพื่อใช้เป็นพื้นฐานในการอธิบายและสนับสนุนการวิเคราะห์ข้อมูลในบทถัดไป

2.1 แนวคิดเกี่ยวกับการวิเคราะห์ข้อมูล (Data Analysis)

การวิเคราะห์ข้อมูล (Data Analysis) เป็นกระบวนการนำข้อมูลที่มีอยู่มาประมวลผล เพื่อตอบคำถามหรือหาความสัมพันธ์ระหว่างตัวแปรต่าง ๆ โดยอาจใช้วิธีการทางสถิติหรือแบบจำลองทางคณิตศาสตร์เข้ามาช่วยในการวิเคราะห์ ในการศึกษาครั้งนี้ ใช้การวิเคราะห์ข้อมูลเชิงพรรณนา (Descriptive Analysis) ร่วมกับแบบจำลองทางความน่าจะเป็น เพื่อศึกษาความสัมพันธ์ระหว่างผลการเรียน ประสบการณ์ฝึกงาน และสถานการณ์มีงานทำ (coursera, 2025)

2.2 ทฤษฎีความน่าจะเป็น (Probability Theory)

ความน่าจะเป็น (Probability) เป็นเครื่องมือทางคณิตศาสตร์ที่ใช้ในการวัดโอกาสของเหตุการณ์หนึ่ง ๆ โดยมีค่าระหว่าง 0 ถึง 1 โดยกำหนดให้ $P(A)$ แทนความน่าจะเป็นของเหตุการณ์ A มีคุณสมบัติสำคัญ ได้แก่

- $0 \leq P(A) \leq 1$
- $P(S) = 1$ เมื่อ S คือ sample space

2.2.1 ความน่าจะเป็นแบบมีเงื่อนไข (Conditional Probability)

ความน่าจะเป็นแบบมีเงื่อนไข คือ ความน่าจะเป็นของเหตุการณ์หนึ่ง เมื่อทราบว่าอีกเหตุการณ์หนึ่งเกิดขึ้นแล้ว

$$P(A | B) = \frac{P(A \cap B)}{P(B)}$$

ในการศึกษาครั้งนี้ ใช้ในการคำนวณความน่าจะเป็นของการมีงานทำ เมื่อทราบสถานะของนักศึกษา (State)

2.3 แนวคิดเกี่ยวกับ Markov Chain

Markov Chain เป็นแบบจำลองทางคณิตศาสตร์ที่ใช้ในการอธิบายการเปลี่ยนแปลงของระบบจากสถานะหนึ่งไปยังอีกสถานะหนึ่ง โดยมีสมบัติสำคัญคือ ความน่าจะเป็นของสถานะในอนาคตขึ้นอยู่กับสถานะปัจจุบันเท่านั้น เรียกว่า **Markov Property** (Brilliant, 2026)

2.3.1 Transition Probability

ความน่าจะเป็นในการเปลี่ยนจากสถานะ i ไปยังสถานะ j เขียนได้เป็น

$$P_{ij} = P(X_{t+1} = j \mid X_t = i)$$

โดยที่

- X_t คือ สถานะในช่วงเวลา t
- P_{ij} คือ transition probability

2.3.2 Transition Matrix

Transition Matrix เป็นเมทริกซ์ที่เก็บค่าความน่าจะเป็นของการเปลี่ยนสถานะทั้งหมด

$$P = \begin{bmatrix} P_{11} & P_{12} & P_{13} \\ P_{21} & P_{22} & P_{23} \\ P_{31} & P_{32} & P_{33} \end{bmatrix}$$

โดยแต่ละแถวจะมีผลรวมเท่ากับ 1

2.3.3 การคำนวณความน่าจะเป็นจากข้อมูล

ในการศึกษานี้ ความน่าจะเป็นถูกคำนวณจากความถี่ของข้อมูล โดยใช้สูตร

$$P = \frac{\text{จำนวนเหตุการณ์ที่สนใจ}}{\text{จำนวนทั้งหมดในสถานะนั้น}}$$

เช่น

$$P(\text{Employed} \mid \text{State}) = \frac{\text{จำนวนผู้ที่ได้งานใน State นั้น}}{\text{จำนวนทั้งหมดใน State นั้น}}$$

2.4 โซ่มาร์คอฟแบบดูดกลืน (Absorbing Markov Chain)

Absorbing Markov Chain เป็นกรณีพิเศษของ Markov Chain ที่มีสถานะบางสถานะเรียกว่า Absorbing State เงื่อนไขของ Absorbing State คือ $P_{ij} = 1$ นั่นคือ ต้องมีอย่างน้อย 1 absorbing state และจากทุก state ต้องสามารถไปถึง absorbing state ได้ ซึ่งในการศึกษานี้ Employed และ Unemployed ถูกกำหนดให้เป็น Absorbing States

2.5 งานวิจัยที่เกี่ยวข้อง

งานวิจัยของ Zbiciak et al. (2025) ได้นำแนวคิดของ Markov Chain มาประยุกต์ใช้ในการวิเคราะห์และพยากรณ์อายุการใช้งานของอาคารและองค์ประกอบโครงสร้าง โดยมองสภาพของโครงสร้างเป็นชุดของสถานะ (states) ที่สามารถเปลี่ยนแปลงไปตามเวลา เช่น จากสภาพดีไปสู่สภาพเสื่อมและสุดท้ายเข้าสู่สภาวะล้มเหลว ซึ่งถือเป็นสถานะดูดกลืน (absorbing state) งานวิจัยนี้ใช้ทั้งแบบเวลาไม่ต่อเนื่องและเวลาแบบต่อเนื่องในการสร้างแบบจำลองการเปลี่ยนสถานะ พร้อมทั้งใช้เมทริกซ์ความน่าจะเป็นในการอธิบายพฤติกรรมของระบบ และคำนวณค่าเวลาคาดหวังก่อนที่ระบบจะเข้าสู่สภาวะสุดท้าย นอกจากนี้ยังมีการพัฒนาแบบจำลองแบบ Fuzzy Markov Chain เพื่อรองรับความไม่แน่นอนของข้อมูลในโลกจริง เช่น ความคลาดเคลื่อนในการประเมินสภาพโครงสร้าง เมื่อพิจารณาเชื่อมโยงกับงานของผู้วิจัยจะเห็นว่าทั้งสองงานมีแนวคิดพื้นฐานเดียวกันคือการใช้ Markov Chain ในการอธิบายการเปลี่ยนแปลงของสถานะตามความน่าจะเป็น แม้ว่าการวิจัยนี้จะศึกษาด้านวิศวกรรมโครงสร้าง ส่วนงานของผู้วิจัยอาจเน้นไปที่การวิเคราะห์ผลลัพธ์ เช่น การเปลี่ยนแปลงของระดับผลการเรียน แต่ทั้งสองกรณีล้วนใช้เมทริกซ์ความน่าจะเป็นในการพยากรณ์พฤติกรรมของระบบในอนาคต และมีแนวคิดของสถานะปลายทางหรือสถานะดูดกลืนที่คล้ายคลึงกัน ดังนั้น งานวิจัยนี้จะช่วยสนับสนุนแนวคิดว่าการใช้ Markov Chain เป็นวิธีที่เหมาะสมในการวิเคราะห์ระบบที่มีการเปลี่ยนสถานะแบบสุ่ม และสามารถนำไปประยุกต์ใช้ได้หลากหลายบริบท รวมถึงงานของผู้วิจัยได้อย่างมีประสิทธิภาพ

งานวิจัยของ Scrivano และ Tolio (2021) ได้นำแบบจำลอง Markov Chain มาใช้ในการประเมินประสิทธิภาพของสายการผลิต (manufacturing lines) โดยพิจารณาสถานะของระบบในแต่ละช่วงเวลา เช่น สถานะการทำงานปกติ การหยุดทำงาน หรือความล่าช้า และใช้ความน่าจะเป็นในการเปลี่ยนผ่านระหว่างสถานะเพื่อจำลองพฤติกรรมของระบบในระยะยาว งานวิจัยนี้มีการพัฒนาแบบจำลองให้สามารถรองรับเวลาในการประมวลผลที่มีความไม่แน่นอน (general processing times) ซึ่งทำให้สามารถวิเคราะห์ประสิทธิภาพของระบบได้ใกล้เคียงกับสถานการณ์จริงมากขึ้น ผลการศึกษาพบว่า Markov Chain สามารถใช้ประเมินตัวชี้วัดสำคัญ เช่น throughput และประสิทธิภาพของระบบได้อย่างมีประสิทธิภาพ และช่วยสนับสนุนการตัดสินใจในการปรับปรุงกระบวนการผลิต เมื่อเชื่อมโยงกับงานของผู้วิจัย จะเห็นว่าทั้งสองงานใช้แนวคิดเดียวกันในการอธิบายการเปลี่ยนแปลงของสถานะของระบบผ่านความน่าจะเป็น แม้ว่าการวิจัยนี้จะเน้นด้านอุตสาหกรรมการผลิต ส่วนงานของผู้วิจัยเน้นด้านการศึกษา แต่หลักการของ Markov Chain ในการพยากรณ์พฤติกรรมของระบบในอนาคตยังคงสอดคล้องกัน ซึ่งแสดงให้เห็นถึงความยืดหยุ่นของแบบจำลองที่สามารถนำไปประยุกต์ใช้ได้หลากหลายบริบท

เอกสารของ Grinstead และ Snell ในหัวข้อ Absorbing Markov Chains เป็นการอธิบายแนวคิดพื้นฐานของมาร์คอฟเชนที่มี “สถานะดูดกลืน” อย่างเป็นระบบ โดยกล่าวถึงลักษณะของสถานะที่เมื่อเข้าสู่แล้วจะไม่สามารถย้ายไปสถานะอื่นได้ พร้อมทั้งแสดงวิธีการจัดรูปเมทริกซ์ความน่าจะเป็นให้อยู่ในรูปมาตรฐาน (canonical form) เพื่อแยกสถานะชั่วคราว (transient states) ออกจากสถานะดูดกลืนได้อย่างชัดเจน นอกจากนี้ยังนำเสนอเครื่องมือสำคัญ เช่น เมทริกซ์พื้นฐาน (fundamental matrix) ซึ่งใช้ในการคำนวณจำนวนครั้งคาดหวังที่ระบบจะอยู่ในสถานะต่าง ๆ ก่อนถูกดูดกลืน รวมถึงการหาความน่าจะเป็นที่ระบบจะจบลงในแต่ละสถานะปลายทาง ผลลัพธ์ของเอกสารนี้ชี้ให้เห็นว่าสามารถวิเคราะห์พฤติกรรมระยะยาวของระบบได้อย่างแม่นยำ โดยเฉพาะการคำนวณเวลาเฉลี่ยก่อนเข้าสู่สถานะดูดกลืนและโอกาสในการเข้าสู่แต่ละสถานะสุดท้าย ซึ่งเป็นประโยชน์อย่างมากในการศึกษาระบบที่มีจุดสิ้นสุดที่ชัดเจน เมื่อเชื่อมโยงกับงานของผู้วิจัย แนวคิดดังกล่าวมีความสอดคล้องโดยตรง เนื่องจากการใช้ Absorbing Markov Chain ในการวิเคราะห์การเปลี่ยนแปลงของสถานะ เช่น ระดับผลการเรียน สามารถกำหนดให้สถานะสุดท้าย เช่น การจบการศึกษาหรือการผ่าน/ไม่ผ่าน เป็นสถานะดูดกลืนได้ ทำให้สามารถนำวิธีการจากเอกสารนี้มาคำนวณทั้งความน่าจะเป็นของผลลัพธ์ในอนาคต และจำนวนช่วงเวลาที่คาดว่าจะเกิดขึ้นก่อนถึงสถานะปลายทางได้อย่างเป็นระบบและมีประสิทธิภาพ

บทที่ 3 วัสดุอุปกรณ์และวิธีการ

บทนี้เป็นการอธิบายถึงวัสดุ อุปกรณ์ และขั้นตอนการดำเนินงานที่ใช้ในการศึกษา โดยครอบคลุม ตั้งแต่การรวบรวมข้อมูล การเตรียมข้อมูล การจัดกลุ่มตัวแปร และการวิเคราะห์ข้อมูลด้วยแบบจำลอง Absorbing Markov Chain เพื่อให้สามารถประเมินความน่าจะเป็นของการมีงานทำของนักศึกษาได้อย่างเป็นระบบ

3.1 วัสดุและอุปกรณ์

ในการดำเนินการศึกษาครั้งนี้ ผู้จัดทำได้ใช้วัสดุและอุปกรณ์ที่สำคัญดังต่อไปนี้

3.1.1 ชุดข้อมูล (Dataset)

เป็นข้อมูลทุติยภูมิที่ประกอบด้วยตัวแปรที่เกี่ยวข้องกับนักศึกษา ได้แก่

- CGPA (เกรดเฉลี่ยสะสม)
- Internships (จำนวนครั้งการฝึกงาน)
- Placement Status (สถานะการมีงานทำ)

ข้อมูลดังกล่าวถูกนำมาใช้เป็นแหล่งข้อมูลหลักในการวิเคราะห์

3.1.2 คอมพิวเตอร์ (Computer)

ใช้สำหรับการจัดเก็บข้อมูล ประมวลผล และวิเคราะห์ข้อมูล

3.1.3 โปรแกรม Microsoft Excel

ใช้เป็นเครื่องมือหลักในการวิเคราะห์ข้อมูล โดยมีการใช้งานฟังก์ชันและเครื่องมือต่าง ๆ ได้แก่

- การใช้สูตร (Formula) เช่น IF เพื่อจัดกลุ่มข้อมูล
- การใช้ Pivot Table เพื่อสรุปและคำนวณความถี่ของข้อมูล
- การใช้เครื่องมือ Conditional Formatting เพื่อแสดงผลในรูปแบบ Heatmap
- การสร้างกราฟ (Chart) เพื่อแสดงผลการวิเคราะห์

3.1.4 โปรแกรมประมวลผลคำ (Microsoft Word)

ใช้สำหรับจัดทำรายงานฉบับสมบูรณ์

3.2 วิธีการ

การดำเนินงานในครั้งนี้ประกอบด้วยขั้นตอนหลักดังต่อไปนี้

3.2.1 การรวบรวมข้อมูล

ข้อมูลที่ใช้ในการศึกษานี้เป็นข้อมูลทุติยภูมิ ซึ่งผู้จัดทำได้นำมาจากชุดข้อมูลที่เกี่ยวข้องกับการคาดการณ์สถานะการมีงานทำของนักศึกษา โดยข้อมูลประกอบด้วยตัวแปรที่สำคัญ ได้แก่ CGPA จำนวนการฝึกงาน และสถานะการมีงานทำ

3.2.2 การเตรียมข้อมูล (Data Preprocessing)

1. การจัดกลุ่ม (CGPA) แบ่ง CGPA ออกเป็น 4 ระดับ ได้แก่
 - Excellent (≥ 8.0)
 - Good (6.5 – 7.99)
 - Average (5.0 – 6.49)
 - Low (< 5.0)
2. การจัดกลุ่มจำนวนการฝึกงาน แบ่งออกเป็น 2 ระดับ ได้แก่
 - High (≥ 4 ครั้ง)
 - Low (< 4 ครั้ง)
3. การสร้างสถานะ (State) นำค่าจาก CGPA และ Internships รวมกันเพื่อสร้างสถานะ ได้แก่
 - E_Hi (Excellent CGPA + High Internship)
 - E_Lo (Excellent CGPA + Low Internship)
 - G_Hi (Good CGPA + High Internship)
 - G_Lo (Good CGPA + Low Internship)
 - A_Hi (Average CGPA + High Internship)
 - A_Lo (Average CGPA + Low Internship)
 - L_Hi (Low CGPA + High Internship)
 - L_Lo (Low CGPA + Low Internship)

3.2.3 การวิเคราะห์ข้อมูลด้วย Pivot Table

1. นำข้อมูลที่เตรียมไว้เข้าสู่โปรแกรม Microsoft Excel
2. สร้าง Pivot Table โดยกำหนด
 - Rows = State
 - Columns = Placement Status (Employed / Unemployed)
 - Values = Count ของ Placement Status
3. แปลงค่าความถี่เป็นความน่าจะเป็น โดยใช้
 - Show Values As $\rightarrow$ % of Row Total

3.2.4 การสร้างแบบจำลอง Absorbing Markov Chain

กำหนดให้

- State จาก CGPA และ Internships เป็นสถานะเริ่มต้น (Transient States)
- Employed และ Unemployed เป็นสถานะปลายทาง (Absorbing States)

จากนั้นใช้ค่าความน่าจะเป็นที่ได้จาก Pivot Table ในการสร้าง Transition Matrix เพื่อแสดงโอกาสที่แต่ละสถานะจะเข้าสู่สถานะการมีงานทำหรือไม่มีงานทำ

3.2.5 การแสดงผลและวิเคราะห์ข้อมูล

1. แสดงผลในรูปแบบตาราง Transition Matrix
2. ใช้กราฟแท่ง (Bar Chart) เพื่อช่วยในการแสดงผล
3. วิเคราะห์ความสัมพันธ์ระหว่าง CGPA การฝึกงาน และสถานะการมีงานทำ

บทที่ 4 ผลและวิจารณ์

บทนี้เป็นการนำเสนอผลการวิเคราะห์ข้อมูลที่ได้จากการประยุกต์ใช้แบบจำลอง Absorbing Markov Chain เพื่อศึกษาความน่าจะเป็นของการมีงานทำของนักศึกษา โดยพิจารณาจากผลการเรียนเฉลี่ยสะสม (CGPA) และประสบการณ์การฝึกงาน (Internships) ซึ่งผลการวิเคราะห์จะแสดงในรูปแบบของตาราง (Transition Matrix) และกราฟ พร้อมทั้งมีการอธิบายและวิจารณ์ผลที่ได้จากการศึกษา

4.1 ผลการวิเคราะห์ข้อมูล

4.1.1 ตาราง Transition Matrix

ตารางที่ 4.1 ความน่าจะเป็นของการมีงานทำและไม่มีการมีงานทำในแต่ละสถานะ


<i>State</i>	<i>Employed</i>	<i>Unemployed</i>
<i>A_HI</i>	0.6016	0.3984
<i>A_LO</i>	0.5297	0.4703
<i>E_HI</i>	0.6266	0.3734
<i>E_LO</i>	0.5449	0.4551
<i>G_HI</i>	0.6230	0.3770
<i>G_LO</i>	0.5391	0.4609
<i>L_HI</i>	0.5526	0.4474
<i>L_LO</i>	0.5099	0.4901

จากตารางที่ 4.1 พบว่า นักศึกษาที่อยู่ในสถานะ *E_HI* มีความน่าจะเป็นในการได้งานทำสูงที่สุด โดยมีค่าเท่ากับ 0.6266 ในขณะที่นักศึกษาที่อยู่ในสถานะ *L_LO* มีโอกาสได้งานต่ำที่สุด โดยมีค่าเท่ากับ 0.5099 นอกจากนี้ เมื่อพิจารณาเปรียบเทียบระหว่างกลุ่มที่มีประสบการณ์ฝึกงานสูงและต่ำ พบว่า

- กลุ่ม *A_HI* มีโอกาสได้งาน 0.6016 สูงกว่ากลุ่ม *A_LO* ที่มีโอกาสได้งาน 0.5297
- กลุ่ม *G_HI* มีโอกาสได้งาน 0.6230 สูงกว่ากลุ่ม *G_LO* ที่มีโอกาสได้งาน 0.5391

ซึ่งแสดงให้เห็นว่า ประสบการณ์การฝึกงานมีผลเชิงบวกต่อโอกาสในการได้งานทำ โดยนักศึกษาที่มีการฝึกงานในระดับสูง (HI) มีแนวโน้มที่จะได้รับการจ้างงานมากกว่านักศึกษาที่มีการฝึกงานในระดับต่ำ (LO) ในทุกระดับของผลการเรียน

4.2 การแสดงผลด้วยกราฟ



รูปที่ 4.1 กราฟแท่งแสดงความน่าจะเป็นของการมีงานทำในแต่ละสถานะ
จากรูปที่ 4.1 พบว่า กลุ่ม E_HI มีค่าสูงที่สุด ขณะที่กลุ่ม L_LO มีค่าต่ำที่สุด ซึ่งสอดคล้องกับผลจาก
ตารางที่ 4.1

4.3 การวิจารณ์ผล

จากผลการวิเคราะห์ สามารถอภิปรายได้ดังนี้

4.3.1 ผลของ CGPA ต่อการมีงานทำ

พบว่า นักศึกษาที่มีผลการเรียนในระดับ Excellent (E) มีโอกาสได้งาน สูงที่สุด (0.6266 ในกลุ่ม E_HI) เมื่อเปรียบเทียบกับกลุ่มอื่น ซึ่งแสดงให้เห็นว่า ผลการเรียนเฉลี่ยสะสมเป็นปัจจัยสำคัญที่ส่งผลต่อโอกาสในการได้งาน โดยนักศึกษาที่มีผลการเรียนสูงมักได้รับการพิจารณามากกว่า

4.3.2 ผลของการฝึกงานต่อการมีงานทำ

พบว่า นักศึกษาที่มีประสบการณ์ฝึกงานในระดับ High (HI) มีโอกาสได้งาน สูงกว่า กลุ่ม Low (LO) อย่างสม่ำเสมอในทุกะดับของผลการเรียน เช่น

- A_HI (0.6016) > A_LO (0.5297)
- G_HI (0.6230) > G_LO (0.5391)

ซึ่งแสดงให้เห็นว่า ประสบการณ์การฝึกงานมีผลเชิงบวกต่อโอกาสในการได้งาน และช่วยเพิ่มความสามารถในการแข่งขันในตลาดแรงงาน

4.3.3 การวิเคราะห์ภาพรวม

โดยรวมแล้ว ปัจจัยด้าน ผลการเรียนรู้เฉลี่ยสะสม (CGPA) และประสบการณ์การฝึกงาน (Internships) มีบทบาทสำคัญต่อโอกาสในการมีงานทำ โดยเฉพาะในกลุ่ม นักศึกษาที่มีผลการเรียนระดับสูงและมีประสบการณ์ฝึกงานในระดับสูง (E_HI) ซึ่งมีแนวโน้มได้รับการจ้างงานมากที่สุด

4.3.4 ข้อเสนอแนะจากข้อมูล

จากข้อมูลพบว่า แม้นักศึกษาที่มีผลการเรียนในระดับต่ำ (Low) หากมีประสบการณ์ฝึกงานในระดับสูง (L_HI) ก็ยังมีโอกาสได้งานมากกว่ากลุ่มที่ไม่มีประสบการณ์ฝึกงาน (L_LO) ซึ่งอาจเกิดจากนายจ้างให้ความสำคัญกับประสบการณ์การทำงานจริงและทักษะที่สามารถนำไปใช้ได้ทันที มากกว่าผลการเรียนเพียงอย่างเดียว

บทที่ 5 สรุปและข้อเสนอแนะ

บทนี้เป็นการสรุปผลการศึกษาและนำเสนอข้อเสนอแนะจากการวิเคราะห์ข้อมูล โดยอาศัยแบบจำลอง Absorbing Markov Chain เพื่อศึกษาความน่าจะเป็นของการมีงานทำของนักศึกษา ซึ่งพิจารณาจากผลการเรียนเฉลี่ยสะสมและประสบการณ์การฝึกงาน ทั้งนี้เพื่อให้ได้ข้อสรุปที่สามารถนำไปประยุกต์ใช้ได้จริง และเป็นแนวทางสำหรับการศึกษาต่อไปในอนาคต

5.1 สรุป

จากการศึกษาพบว่า ปัจจัยด้านผลการเรียนเฉลี่ยสะสม (Cumulative Grade Point Average: CGPA) และประสบการณ์การฝึกงาน (Internships) มีผลต่อโอกาสในการมีงานทำของนักศึกษาอย่างชัดเจน โดยนักศึกษาที่มีผลการเรียนในระดับสูงและมีประสบการณ์ฝึกงานมาก มีแนวโน้มที่จะได้รับการจ้างงานสูงกว่านักศึกษากลุ่มอื่น

จากการวิเคราะห์ด้วยแบบจำลอง Absorbing Markov Chain พบว่า แต่ละสถานะของนักศึกษาซึ่งประกอบด้วยระดับผลการเรียนและระดับการฝึกงาน มีความน่าจะเป็นในการเข้าสู่สถานะการมีงานทำ (Employed) และไม่มีการมีงานทำ (Unemployed) แตกต่างกัน โดยสถานะ E_HI (Excellent CGPA และมีประสบการณ์ฝึกงานระดับสูง) มีโอกาสได้งานสูงที่สุด ขณะที่สถานะ L_LO (Low CGPA และมีประสบการณ์ฝึกงานระดับต่ำ) มีโอกาสได้งานต่ำที่สุด

นอกจากนี้ ยังพบว่าประสบการณ์การฝึกงานมีบทบาทสำคัญในการเพิ่มโอกาสในการได้งาน แม้ในกรณีที่นักศึกษามีผลการเรียนอยู่ในระดับปานกลาง เช่น สถานะ A_HI (Average CGPA และมีประสบการณ์ฝึกงานระดับสูง) ซึ่งมีโอกาสได้งานสูงกว่าสถานะ A_LO (Average CGPA และมีประสบการณ์ฝึกงานระดับต่ำ) อย่างชัดเจน

ผลการศึกษาชี้ให้เห็นว่า การมีประสบการณ์การทำงานจริงสามารถช่วยเพิ่มศักยภาพในการแข่งขันในตลาดแรงงาน และเป็นปัจจัยสำคัญที่ช่วยเสริมผลการเรียนให้มีประสิทธิภาพมากยิ่งขึ้นในการพิจารณาการจ้างงาน

5.2 ข้อเสนอแนะ

จากผลการศึกษา สามารถเสนอแนะแนวทางดังต่อไปนี้

5.2.1 สำหรับนักศึกษา ควรให้ความสำคัญทั้งด้านผลการเรียนและการพัฒนาทักษะผ่านการฝึกงาน เนื่องจากทั้งสองปัจจัยมีผลต่อโอกาสในการได้งาน โดยเฉพาะการฝึกงานที่ช่วยเพิ่มประสบการณ์ และทักษะที่จำเป็นในการทำงานจริง

5.2.2 สำหรับสถาบันการศึกษา ควรส่งเสริมและสนับสนุนโอกาสในการฝึกงานให้นักศึกษา เช่น การจัดโครงการฝึกงานหรือความร่วมมือกับสถานประกอบการ เพื่อเพิ่มโอกาสในการได้งานหลังสำเร็จการศึกษา

5.2.3 สำหรับการศึกษาครั้งต่อไป ควรพิจารณาเพิ่มตัวแปรอื่น ๆ ที่อาจมีผลต่อการได้งาน เช่น ทักษะด้านการสื่อสาร คะแนนทดสอบความถนัด หรือกิจกรรมเสริมหลักสูตร เพื่อให้การวิเคราะห์มีความครอบคลุมมากยิ่งขึ้น

นอกจากนี้ อาจนำแบบจำลองอื่น ๆ เช่น Machine Learning มาประยุกต์ใช้ร่วมกับ Markov Chain เพื่อเพิ่มความแม่นยำในการพยากรณ์

เอกสารอ้างอิง

Brilliant. (2026). **Absorbing Markov chain**

Source: <https://brilliant.org/wiki/absorbing-markov-chains/>, 22 March 2026

Coursera. (2025). **What Is Data Analysis? (With Examples)**

Source: <https://www.coursera.org/articles/what-is-data-analysis-with-examples>,
22 March 2026

Geeksforgeeks. (2025). **Markov Chain**

Source: <https://www.geeksforgeeks.org/machine-learning/markov-chain/>, 22 March
2026

Powell V. (2025). **Markov Chains Explained Visually**

Source: <https://setosa.io/ev/markov-chains/>, 22 March 2026

Scrivano S., & Tolio T. (2021). **A Markov Chain model for the performance evaluation
of manufacturing lines with general processing times**

Source: <https://www.sciencedirect.com/science/article/pii/S221282712100843X>,
22 March 2026

Wikipedia. (2026). **Absorbing Markov chain**

Source: https://en.wikipedia.org/wiki/Absorbing_Markov_chain, 22 March 2026

Yashinski A. (2021). **Absorbing Markov Chains**

Source: [https://www.math.umd.edu/~immortal/MATH401/book/ch_absorbing_
markov_chains.pdf](https://www.math.umd.edu/~immortal/MATH401/book/ch_absorbing_markov_chains.pdf), 22 March 2026

Zbiciak A., Walasek D., & Nagirniak M. (2025). **Markov Chain Modeling for Predicting the
Service Life of Buildings and Structural Components**

Source: <https://www.mdpi.com/2076-3417/15/17/9287>, 22 March 2026