

การประยุกต์ใช้อัลกอริทึม PageRank เพื่อวิเคราะห์อิทธิพลของนักแสดงในเครือข่าย
ภาพยนตร์ IMDb

จัดทำโดย

นายกิตติพัฒน์	วรารังสีโรจน์	6510401533
นางสาวเพชรศิณี	ตรงเพ็ชร	6510401801
นายภัทรพงศ์	ชนะอาภา	6510401827
นางสาวอ้อมใจ	ใจใหญ่	6510402050

ภายใต้การควบคุมของ

ดร.ชานนท์ ทองประยูร

รายงานนี้เป็นส่วนหนึ่งของวิชาเลือกเฉพาะทางสถิติ 01422496

ภาคต้น ปีการศึกษา 2568

ภาควิชาสถิติ คณะวิทยาศาสตร์

มหาวิทยาลัยเกษตรศาสตร์

บทที่ 1 บทนำ

ในปัจจุบันเป็นยุคที่ข้อมูลบนเครือข่ายอินเทอร์เน็ตขยายตัวอย่างรวดเร็วและไร้ขอบเขต การสืบค้นข้อมูลอย่างมีประสิทธิภาพจึงกลายเป็นบทบาทสำคัญของระบบสารสนเทศสมัยใหม่ เวิลด์ไวด์เว็บ (World Wide Web) ซึ่งเกิดขึ้นในช่วงปลายทศวรรษที่ 1980 ได้พัฒนาจนกลายเป็นแหล่งข้อมูลขนาดใหญ่ที่มีทั้งความหลากหลายและความไม่เป็นระเบียบ (Brin & Page, 1998) ทำให้เกิดอุปสรรคสำคัญที่คือการจัดการกับข้อมูลจำนวนมากมหาศาลที่ถูกสร้างขึ้นอย่างไร้การควบคุมคุณภาพหรือมาตรฐาน ส่งผลให้เครื่องมือค้นหา (Search Engines) จำเป็นต้องพัฒนาแนวทางใหม่ในการระบุและจัดลำดับความสำคัญของหน้าเว็บ (Webpages) ตามระดับความเกี่ยวข้องและความน่าเชื่อถืออย่างแม่นยำ

ก่อนการพัฒนาอัลกอริทึม PageRank เครื่องมือค้นหาส่วนใหญ่ใช้หลักการประเมินโดยอิงจากเนื้อหาภายในหน้าเว็บ (Content-based Ranking) เช่น การนับคำสำคัญ (Term Frequency) หรือการจับคู่คำในข้อความ (Keyword Matching) (Manning, Raghavan, & Schütze, 2008) แม้ว่าวิธีดังกล่าวจะมีประสิทธิภาพแต่กลับมีข้อจำกัดคือสามารถถูกบิดเบือนได้ง่ายจากการปรับแต่งคำภายในหน้าเว็บเพื่อเพิ่มลำดับการปรากฏในผลการค้นหา ถัดมา Larry Page และ Sergey Brin จากมหาวิทยาลัย Stanford ได้เสนอแนวคิด อัลกอริทึม PageRank ในปี ค.ศ. 1998 ซึ่งถือเป็นจุดเปลี่ยนสำคัญของเทคโนโลยีการค้นหาข้อมูลบนเว็บ (Page, Brin, Motwani, & Winograd, 1999) โดยอัลกอริทึมดังกล่าวใช้หลักการ การอ้างอิงผ่านลิงก์ (Link Citation) เพื่อประเมินระดับความสำคัญของหน้าเว็บ กล่าวคือ หากหน้าเว็บหนึ่งได้รับการเชื่อมโยง (Hyperlink) จากหน้าอื่น ๆ จำนวนมาก หน้าเว็บนั้นก็จะได้รับค่าความสำคัญที่สูงขึ้นตามไปด้วย แนวคิดนี้เปรียบเสมือน การโหวตความน่าเชื่อถือ ที่เกิดขึ้นโดยธรรมชาติบนโครงสร้างลิงก์ของเว็บ (Langville & Meyer, 2006)

ในเชิงคณิตศาสตร์ PageRank ใช้หลักการของทฤษฎีห่วงโซ่มาร์คอฟจำลองพฤติกรรมของนักท่องเที่ยวแบบสุ่ม โดยผู้ใช้มีโอกาสคลิกลิงก์ไปยังหน้าอื่น หรือกระโดดไปยังหน้าใด ๆ ภายในระบบ ซึ่งเรียกระเบียบการกระโดดนี้ว่า Teleportation (Page et al., 1999) การคำนวณ PageRank สามารถแสดงเป็นสมการเชิงเส้นของเมทริกซ์ และใช้วิธีการทำซ้ำเพื่อหาค่าเวกเตอร์อันดับ (Rank Vector) ที่สะท้อนความสำคัญสัมพัทธ์ของแต่ละหน้าเว็บ

การนำแนวคิด PageRank ไปประยุกต์ใช้ในระบบค้นหา Google แสดงให้เห็นถึงประสิทธิภาพของการใช้โครงสร้างลิงก์ในการจัดอันดับผลลัพธ์การค้นหา ทำให้ผู้ใช้งานสามารถเข้าถึงข้อมูลที่มีความเกี่ยวข้องและมีความน่าเชื่อถือได้มากกว่าระบบที่ใช้เพียงการประเมินจากเนื้อหาภายในหน้า (Langville & Meyer, 2006) ปัจจุบันแนวคิดของ PageRank ได้กลายเป็นพื้นฐานของเทคนิคการจัดอันดับเชิงโครงสร้าง (Link-based Ranking) และถูกพัฒนาต่อยอดเป็นอัลกอริทึมรูปแบบต่าง ๆ เช่น HITS Algorithm และ Personalized PageRank ซึ่งได้รับ

การประยุกต์ใช้อย่างกว้างขวาง ทั้งในการค้นหาข้อมูล การวิเคราะห์เครือข่ายสังคมออนไลน์ และการจัดลำดับข้อมูลในกราฟขนาดใหญ่

โดยสรุป คือ อัลกอริทึม PageRank ไม่เพียงแต่เป็นกลไกหลักของการจัดอันดับหน้าเว็บในเครื่องมือค้นหาสมัยใหม่ แต่ยังเป็นพื้นฐานสำคัญของการจัดอันดับบนเว็บ (Web Ranking) ซึ่งสะท้อนให้เห็นถึงการประยุกต์ใช้คณิตศาสตร์เชิงเส้นและทฤษฎีกราฟในการจัดระเบียบข้อมูลจำนวนมหาศาลในโลกดิจิทัลได้อย่างมีระบบ

บทที่ 2 วิธีการ

บทนี้จะอธิบายถึงการนำอัลกอริทึมทางคณิตศาสตร์ที่ใช้ในการคำนวณ PageRank มาใช้ในกระบวนการ PageRank with teleportation รวมทั้งการประยุกต์ใช้ในบริบทของการวิเคราะห์เครือข่ายนักแสดง โดยทางผู้ศึกษาได้เลือกใช้ข้อมูลจากฐานข้อมูล IMDb ซึ่งเป็นแหล่งที่รวบรวมข้อมูลเกี่ยวกับภาพยนตร์ นักแสดง และบุคคลในวงการบันเทิงจากทั่วโลก

2.1 Pagerank

อัลกอริทึมนี้ถูกคิดค้น และพัฒนาโดย Larry Page หนึ่งในผู้ก่อตั้ง Google ในปี ค.ศ. 1998 ถูกใช้ครั้งแรกเพื่อจัดอันดับหน้าเว็บในการค้นหาของ Google ในปัจจุบันอัลกอริทึมนี้ถูกนำไปใช้กันมากยิ่งขึ้นในหลากหลายสาขา เช่น การจัดอันดับผู้ใช้โซเชียลมีเดีย เป็นต้น โดยมีแนวคิดหลัก คือ การจัดลำดับว่าเว็บมีความสำคัญมากหรือน้อยจากจำนวนและคุณภาพของลิงก์ที่เชื่อมเข้ามา แนวคิดนี้ถูกนำมาประยุกต์ใช้กับเครือข่ายอื่น ๆ ได้โดยไม่ได้เฉพาะเว็บไซต์ เช่น เครือข่ายสังคม เครือข่ายงานวิจัย เป็นต้น โดยในรายงานชิ้นนี้ จะถูกนำมาใช้วิเคราะห์เครือข่ายนักแสดงจากฐานข้อมูล IMDb โดยกำหนดให้นักแสดงแต่ละคนเป็น “โหนด (Node)” และการร่วมงานการแสดงกันในภาพยนตร์หรือซีรีส์เดียวกันจะให้เป็น “เส้นเชื่อม (Edge)” โดยค่า Pagerank จะแสดงให้เห็นว่านักแสดงคนใดมีอิทธิพลสูงสุดภายในเครือข่าย (Network) โดยที่นักแสดงที่มีการร่วมงานกับนักแสดงที่มีชื่อเสียงหรือมีเส้นเชื่อมมาก จะทำให้มีคะแนนสูงขึ้นตามไปด้วย

ในการคำนวณ Pagerank แบบดั้งเดิมนั้นมีปัญหาในกรณีที่โหนดไม่มีลิงก์ออก หรือกล่าวคือ เว็บเพจที่ไม่มีลิงก์ขาออก (outlink) ซึ่งโดยทั่วไปเรียกว่า จุดจบ (Dead end) นอกจากนี้ยังอาจเกิดปัญหาอื่น เช่น ในกราฟเว็บนั้น สามารถค้นหาเว็บเพจหนึ่ง (i) ถูกอ้างอิงไปหา เว็บเพจหนึ่ง (j) และเว็บเพจนี้ (j) อ้างอิงไปถึงเว็บเพจแรก (i) ซึ่งในปัญหานี้เราเรียกว่า ปัญหากับดักแมงมุม (Spider trap problem) ในกรณีของกับดักแมงมุม เมื่อมีการสุ่มมาถึงโหนดที่หนึ่ง สามารถข้ามไปโหนดที่สองได้เท่านั้น และจากโหนดสองสามารถไปถึงแค่โหนดหนึ่ง เท่านั้น และจะเป็นเช่นนี้ไปเรื่อย ๆ ส่วนกรณีของจุดจบ (Dead end) เมื่อมาถึงโหนดที่สอง จะไม่สามารถเข้าถึงโหนดอื่น

ต่อได้ เนื่องจากไม่มีเส้นเชื่อมหรือลิงก์ขาออก ทำให้อัลกอริทึมไม่สามารถบรรจบกันได้ เพื่อแก้ปัญหานี้ จึงมีการปรับปรุงโมเดลโดยเพิ่มการเทเลพอร์ต (Teleportation) เข้ามาเพื่อให้ผู้เดินทาง (random walker) มีโอกาสกระโดดไปยังโหนดต่าง ๆ แบบสุ่ม โดยจะมีความน่าจะเป็นเท่ากับ $1-\alpha$ ในขณะที่ α ที่จะเดิมตามลิงก์มีอยู่จริง โดยค่าของ α มักจะกำหนดไว้เท่ากับ 0.85 ตามข้อกำหนดของ Larry Page

2.2 Pagerank with Teleportation

การเทเลพอร์ตประกอบด้วยการเชื่อมต่อโหนดของกราฟเข้ากับโหนดอื่นๆทั้งหมด กราฟจึงจะเสร็จสมบูรณ์ โดยมีแนวคิดที่ประกอบด้วยความน่าจะเป็น α ที่แน่นอน ผู้เดินทาง (Random walker) จะกระโดดไปยังโหนดอื่น ๆ ตามเมทริกซ์ทรานซิชัน P ด้วยความน่าจะเป็น $\frac{1-\alpha}{n}$ โดยจะทำการสุ่มกระโดดไปยังโหนดอื่น ๆ ในกราฟ เราจะได้เมทริกซ์ทรานซิชันใหม่ โดยสมการของแบบจำลอง Pagerank ที่รวมการ Teleportation สามารถเขียนได้ ดังนี้

$$r = \alpha P + (1 - \alpha) v e^T$$

หรือ

$$r = \alpha P + (1 - \alpha) \frac{1}{n} e$$

โดยที่ v เป็นเวกเตอร์ของเลขฐานหนึ่งขนาด $n \times 1$; $v = (1, 1, \dots, 1)^T$

e^T เป็นเวกเตอร์ของ $\frac{1}{n}$; $e^T = \left(\frac{1}{n}, \frac{1}{n}, \dots, \frac{1}{n}\right)$

α โดยทั่วไปจะถูกนิยามว่าค่าตัวประกอบการหน่วง (damping factor) ในการปฏิบัติจะกำหนดให้เท่ากับ 0.85

P คือ เมทริกซ์การเชื่อมโยงของเครือข่ายในรูปแบบ column-stochastic (แต่ละคอลัมน์รวมกันเท่ากับ 1)

ในการคำนวณค่า Pagerank ในทางปฏิบัติจะใช้วิธีวนซ้ำ (Iterative Algorithm) โดยเริ่มจากการกำหนดค่าเริ่มต้นเท่ากันทุกโหนด

$$r^0 = \frac{1}{n} e$$

จากนั้นคำนวณค่าในรอบถัดไปตามสมการ

$$r^{(k+1)} = \alpha P^{(k)} + (1 - \alpha) \frac{1}{n} e$$

จนกว่าค่าความแตกต่างของ Pagerank ระหว่างรอบจะมีค่าน้อยกว่าความคลาดเคลื่อนที่กำหนดไว้ โดยมักจะกำหนดเท่ากับ 10^{-6} หรือ 10^{-8} เป็นไปดังนี้

$$\|r^{(k+1)} - r^{(k)}\| < \varepsilon$$

ในกระบวนการนี้ ค่าที่ได้จะถูกรวบรวมเข้าสู่อันดับ และจะกำหนดเป็นค่า *Pagerank* สุดท้ายของแต่ละโหนด ในกระบวนการวนซ้ำนี้เป็นการประยุกต์ใช้แนวคิดของ *Power method* เป็นวิธีสำหรับหาค่า *Eigenvector* ของเมทริกซ์ โดยจะทำการคูณเวกเตอร์เดิมกับเมทริกซ์ซ้ำไปเรื่อยๆ จนกระทั่งได้ค่าคงที่ หมายความว่ากราฟเข้าสู่

สมดุลแล้ว วิธีนี้สำคัญอย่างมากในการคำนวณ *Pagerank* เพราะสามารถที่จะหาคำตอบได้โดยไม่ต้องแก้สมการเชิงเส้นทั้งหมดพร้อมกัน ซึ่งจะทำให้ซับซ้อนอย่างมากเมื่อมีเครือข่ายขนาดใหญ่

2.3 *Pagerank* เครือข่ายการร่วมงานของนักแสดง

แนวคิดเกี่ยวกับ *Pagerank Centrality* คือการวัดความสำคัญของโหนดในเครือข่ายโดยที่จะอาศัยหลักการของอัลกอริทึม *Pagerank* โดยให้ค่าน้ำหนัก ตามการเชื่อมโยงของโหนดแต่ละโหนดที่มีความสำคัญสูงหรือต่ำแตกต่างกัน เมื่อนำไปประยุกต์การใช้เครือข่ายนักแสดงจากข้อมูลหนังในฐานข้อมูลของ *IMDb* ค่าผลลัพธ์ของ *Pagerank* ที่ได้นั้น จะสะท้อนถึงอิทธิพลของนักแสดงแต่ละคนโครงสร้าง หรือก็คือ นักแสดงที่มีการร่วมถ่ายทำภาพยนตร์หรือซีรีส์ด้วยกันกับนักแสดงที่มีชื่อเสียงหรือมีเชื่อมโยงที่กว้าง จะยังได้ค่าของคะแนน *Pagerank* ที่สูงมากยิ่งขึ้น โดยที่จะแตกต่างกับ *Degree Centrality* ที่ทำการพิจารณาแค่จำนวนของการเส้นเชื่อมเท่านั้น *Pagerank* จึงสามารถที่จะสะท้อนถึงอิทธิพลเชิงคุณภาพของการร่วมงาน ได้ดียิ่งขึ้น อีกทั้งยังเหมาะกับการวิเคราะห์อุตสาหกรรมภาพยนตร์ในระดับโครงสร้าง

บทที่ 3 วิธีการ

การศึกษาครั้งนี้เป็นการศึกษาเพื่อให้เข้าใจแนวคิดและทฤษฎีของการประยุกต์ใช้ PageRank สำหรับการวิเคราะห์ข้อมูลเครือข่ายนักแสดงในวงการบันเทิง โดยมีการใช้ฐานข้อมูลที่มีชื่อ IMDb Movies Dataset (<https://www.kaggle.com/datasets/harshitshankhdhar/imdb-dataset-of-top-1000-movies-and-tv-shows>) ซึ่งเป็นแหล่งที่รวบรวมข้อมูลเกี่ยวกับภาพยนตร์ นักแสดง และบุคคลในวงการบันเทิง ทางผู้ศึกษาเน้นการนำแนวคิด Teleportation มาใช้แก้ปัญหาเพื่อวิเคราะห์ความสัมพันธ์เชิงโครงข่าย โดยการศึกษาประกอบไปด้วยขั้นตอน ดังนี้

3.1 การจำลอง PageRank (PageRank Simulation)

3.1.1 จัดเตรียมข้อมูลโดยใช้ข้อมูลจาก

<https://www.kaggle.com/datasets/harshitshankhdhar/imdb-dataset-of-top-1000-movies-and-tv-shows> ซึ่งประกอบด้วยรายชื่อภาพยนตร์และรายการทีวียอดนิยมจำนวน 1,000 เรื่อง โดยกำหนดให้โหนด แทนด้วยนักแสดง และเส้นเชื่อม แทนด้วย การร่วมงานในภาพยนตร์หรือรายการทีวีเดียวกัน น้ำหนัก แทนด้วยจำนวนครั้งที่นักแสดงคู่นั้นเคยร่วมงานกัน

3.1.2 วิธีการคำนวณ PageRank with Teleportation เพื่อแก้ปัญหาโหนดที่ไม่มีลิงก์ออก (Dead End) และการวนลูบในกราฟ (Spider Trap) โดยใช้สูตร ดังนี้

$$r = \alpha P + (1 - \alpha)ve^T$$

โดย รายละเอียดของสัญลักษณ์อธิบายในส่วนของ 2.2

3.1.2.1 สร้างเมทริกซ์การเชื่อมโยง P จากเครือข่ายนักแสดงที่ร่วมงานกันในรูปแบบ column-stochastic (แต่ละคอลัมน์รวมกันเท่ากับ 1)

3.1.2.2 กำหนด α (damping factor) เท่ากับ 0.85 ใช้ควบคุมความน่าจะเป็นในการเลือกเดินตามเส้นทางเดิมหรือสุ่มเทเลพอร์ตไปยังโหนดอื่น

3.1.2.3 กำหนดเวกเตอร์การเทเลพอร์ต v ให้ทุกค่ามีค่าเท่ากับ $\frac{1}{n}$ เพื่อให้การเทเลพอร์ตมีโอกาสเกิดขึ้นเท่ากันในทุกโหนด

3.1.2.4 ทำการวนซ้ำสมการจนได้ค่า r เข้าสู่สมดุล และหยุดการคำนวณเมื่อค่าความคลาดเคลื่อนระหว่างรอบน้อยกว่าค่า $\epsilon = 10^{-6}$

3.1.2.5 ค่าที่ได้เมื่อเข้าสู่สมดุล จะถือเป็นค่าความสำคัญ (PageRank) สุดท้ายของแต่ละโหนดในเครือข่าย

3.2 การจำลอง Centrality (Centrality Simulation)

3.2.1 การวัดค่าความเป็นจุดศูนย์กลาง (Centrality Measure)

Degree Centrality เป็นการวัดว่าสมาชิกใดบ้างที่เป็นจุดศูนย์กลางของการเชื่อมโยง ซึ่งเป็นตำแหน่งที่มีอิทธิพลสูงสุดในเครือข่าย วัดได้จากจำนวนนักแสดงที่เคยร่วมงานโดยตรงสามารถแบ่งได้เป็น 2 กรณี
กรณีแรก เป็นความสัมพันธ์แบบไม่มีทิศทาง Degree คือจำนวน เส้นเชื่อมโยงทั้งหมดที่เกี่ยวข้องกับสมาชิกหนึ่ง
คำนวณจากจำนวนเส้นเชื่อมโยง (Edges) ทั้งหมดที่เชื่อมกับโหนดหนึ่ง :

$$C_D(v) = \deg(v)$$

โดยที่ $C_D(v)$ คือ ค่าความเป็นจุดศูนย์กลางของโหนด v

กรณีที่สอง เป็นความสัมพันธ์แบบมีทิศทาง แบ่งได้เป็น In-degree คือ จำนวนเส้นเชื่อมโยงที่มีทิศทางเข้าหาสมาชิกหนึ่ง และ Out-degree คือจำนวนเส้นเชื่อมโยงที่มีทิศทางออกจากสมาชิกหนึ่ง

Betweenness Centrality เป็นการวัดว่านักแสดงที่มีตำแหน่งเป็นตัวกลางในการเชื่อมโยงระหว่างระหว่างนักแสดงคนอื่น ๆ สูตรในการคำนวณ :

$$C_B(v) = \sum_{s \neq v \neq t} \frac{\sigma_{st}(v)}{\sigma_{st}}$$

โดยที่ σ_{st} คือ จำนวนเส้นทางที่สั้นที่สุดจากโหนด s ไปยังโหนด t

$\sigma_{st}(v)$ คือ จำนวนเส้นทางที่สั้นที่สุดเหล่านั้นที่ผ่านโหนด v

3.2.2 ผลการจำลองและการเปรียบเทียบความสอดคล้อง

จากการวิเคราะห์และจำลองเครือข่ายนักแสดงโดยใช้การวัดความเป็นจุดศูนย์กลาง (Centrality Measure) ได้แก่ Degree Centrality และ Betweenness Centrality สรุปผลได้ ดังนี้

ตารางที่ 3.1 ตารางแสดงผลการวัดความเป็นจุดศูนย์กลาง ของนักแสดงที่มีคะแนน Page Rank สูงสุด 10 อันดับ

Actor Name	Degree Centrality	Betweenness Centrality
Robert De Niro	45.00	0.0303
Tom Hanks	38.00	0.0192
Clint Eastwood	33.00	0.0155
James Stewart	30.00	0.0195
Al Pacino	35.00	0.0310
Brad Pitt	36.00	0.0272
Christian Bale	31.00	0.0218
Humphrey Bogart	25.00	0.0133
Leonardo DiCaprio	32.00	0.0301
Matt Damon	31.00	0.0219

3.2.2.1 การเปรียบเทียบระหว่าง PageRank และ Degree Centrality ผลการจัดอันดับนักแสดงตามคะแนน PageRank พบว่ามีความสอดคล้องในระดับสูงกับการจัดอันดับตามค่า Degree Centrality กล่าวคือ นักแสดงที่มีคะแนน PageRank สูงสุดมักเป็นบุคคลที่มีจำนวนการร่วมแสดง (Degree Centrality) มากที่สุดเช่นกัน ซึ่งแสดงถึงความสัมพันธ์โดยตรงระหว่าง ปริมาณการเชื่อมโยงกับระดับอิทธิพลในเครือข่าย

3.2.2.2 การเปรียบเทียบระหว่าง PageRank และ Betweenness Centrality ผลการเปรียบเทียบการจัดอันดับตามคะแนน PageRank กับ Betweenness Centrality พบความแตกต่างอย่างมีนัยสำคัญ โดยนักแสดงที่มีค่า PageRank สูงสุดมักไม่ได้อยู่ในลำดับสูงของค่า Betweenness Centrality ตัวอย่างเช่น Robert De Niro ซึ่งมีคะแนน PageRank อันดับที่ 1 แต่มีค่า Betweenness Centrality ต่ำกว่า Al Pacino ซึ่งมีคะแนน PageRank อันดับที่ 5

จากผลดังกล่าวแสดงให้เห็นว่า PageRank และ Degree Centrality วัดอิทธิพลจากจำนวนและคุณภาพของการเชื่อมโยงโดยรอบ และ Betweenness Centrality วัดการเป็นตัวกลางในการเชื่อมโยงระหว่างระหว่างนักแสดงคนอื่น ๆ ดังนั้น แม้นักแสดงบางคนที่มีค่า PageRank สูง แต่ไม่ได้หมายความว่าจะมีบทบาทสำคัญในการเชื่อมโยงระหว่างกลุ่มนักแสดงต่าง ๆ

บทที่ 4 การวิเคราะห์ผลลัพธ์

หลังจากการใช้อัลกอริทึม PageRank with Teleportation ในการวิเคราะห์เครือข่ายนักแสดงโดยใช้ข้อมูลจากเว็บ IMDb ในการสร้างเครือข่ายโดยให้นักแสดงแต่ละคนนั้นเป็นโหนด และการร่วมงานกันในการแสดงภาพยนตร์หรือซีรีส์ในเรื่องเดียวกันแทนเส้นเชื่อมระหว่างโหนด

โดยการคำนวณ ได้กำหนดค่า Damping Factor เท่ากับ 0.85 และค่า $\epsilon = 10^{-6}$ เป็นเกณฑ์ในการหยุดการทำงาน โดยทำการเริ่มจากการกำหนดให้คะแนน PageRank ทุกๆโหนด มีค่าเท่ากัน แล้วทำการทำซ้ำตามสมการของ PageRank with Teleportation จนค่าคะแนน PageRank ในแต่ละโหนดเข้าใกล้ค่าเสถียร โดยแสดงถึงระดับของความสำเร็จของนักแสดงในเครือข่าย

หลักจากการคำนวณนั้น ได้ทำการจัดอันดับนักแสดงตามคะแนน PageRank ที่คำนวณได้ โดยนักแสดงที่มีค่าสูงนั้น หมายถึงนักแสดงที่มีอิทธิพลในเครือข่ายสูง ส่วนนักแสดงที่มีค่าต่ำ หมายถึงนักแสดงที่มีอิทธิพลต่อเครือข่ายน้อย อย่างไรก็ตาม คะแนน PageRank ไม่ได้บ่งบอกถึงความนิยมของนักแสดง แต่บ่งบอกถึงการเชื่อมโยงไปยังนักแสดงคนอื่นๆภายในเครือข่ายนั่นเอง เพื่อให้เห็นภาพรวมของการวิเคราะห์ ได้ทำการแสดงตารางและกราฟการจัดอันดับนักแสดงตามคะแนน PageRank ดังนี้

ตารางที่ 4.1 แสดงผลลัพธ์ของคะแนน PageRank ตามลำดับนักแสดง 50 อันดับ

ลำดับ	นักแสดง	คะแนน PageRank
1.	Robert De Niro	0.002896
2.	Tom Hanks	0.002488
3.	Clint Eastwood	0.002327
4.	James Stewart	0.002103
5.	Al Pacino	0.002102
6.	Brad Pitt	0.001995
7.	Christian Bale	0.001821
8.	Humphrey Bogart	0.001799
9.	Leonardo DiCaprio	0.001789


ตารางที่ 4.1 แสดงผลลัพธ์ของคะแนน PageRank ตามลำดับนักแสดง 50 อันดับ (ต่อ)

ลำดับ	นักแสดง	คะแนน PageRank
10.	Matt Damon	0.001773
11.	Aamir Khan	0.001676
12.	Ethan Hawke	0.001659
13.	Denzel Washington	0.001589
14.	Johnny Depp	0.001546
15.	Michael Caine	0.001526
16.	Scarlett Johansson	0.001495
17.	Toshirô Mifune	0.001447
18.	Charles Chaplin	0.001429
19.	Harrison Ford	0.001374
20.	Shah Rukh Khan	0.001303
21.	Tatsuya Nakadai	0.001293
22.	Edward Norton	0.001282
23.	Cary Grant	0.001279
24.	John Wayne	0.001232
25.	Jake Gyllenhaal	0.001227
26.	Bruce Willis	0.001223
27.	Tom Cruise	0.001222
28.	William Holden	0.001207
29.	Audrey Hepburn	0.001201
30.	Morgan Freeman	0.001200
31.	Russell Crowe	0.001191
32.	Tony Chiu-Wai Leung	0.001177

ตารางที่ 4.1 แสดงผลลัพธ์ของคะแนน PageRank ตามลำดับนักแสดง 50 อันดับ (ต่อ)


ลำดับ	นักแสดง	คะแนน PageRank
33.	Jeff Bridges	0.001152
34.	Joe Pesci	0.001147
35.	Jack Nicholson	0.001144
36.	Gene Hackman	0.001111
37.	Paul Newman	0.001111
38.	Matthew McConaughey	0.001107
39.	Willem Dafoe	0.001103
40.	Katharine Hepburn	0.001098
41.	Dustin Hoffman	0.001091
42.	Tabu	0.001081
43.	Mark Ruffalo	0.001073
44.	Gary Oldman	0.001068
45.	Kang-ho Song	0.001068
46.	Ian McKellen	0.001063
47.	Diane Keaton	0.001057
48.	Gael García Bernal	0.001056
49.	Philip Seymour Hoffman	0.001056
50.	Ed Harris	0.001055

Actor Collaboration Network by PageRank



รูปที่ 4.1 Network Graph แสดงการเชื่อมโยงกันของนักแสดง


รูปที่ 4.2



Bar
Chart

แสดงคะแนน PageRank ของนักแสดงในเครือข่าย

รูปที่ 4.3



Scatter
Plot

แสดงการกระจายของคะแนน PageRank นักแสดงในเครือข่าย

จากกราฟและตาราง สามารถสรุปได้ว่า คะแนน PageRank ของนักแสดง 50 อันดับแรกในฐานข้อมูล IMDb รวมกันเท่ากับ 0.07512 และมีค่าเฉลี่ยเท่ากับ 0.0014102 โดยนักแสดงที่มีคะแนน PageRank สูงที่สุดแสดงถึงอิทธิพลในเครือข่ายที่มากที่สุด ได้แก่ Robert De Niro ซึ่งมีคะแนน PageRank เท่ากับ 0.002896 แสดงถึงการเป็นศูนย์กลางของเครือข่ายที่มีการเชื่อมโยงไปยังนักแสดงคนอื่นค่อนข้างมาก จากผลลัพธ์จะเห็นได้ว่านักแสดงบางคนที่มีชื่อเสียงในวงการบันเทิงระดับโลก ยกตัวอย่างเช่น Tom Cruise อันดับที่ 27 หรือ Morgan Freeman อันดับที่ 30 กลับมีคะแนนน้อยกว่านักแสดงที่มีผลงานที่ไม่โดดเด่น หรือไม่นิยมเท่า อย่างเช่น Clint Eastwood ซึ่งอยู่ในอันดับที่ 3 สิ่งนี้แสดงให้เห็นว่าค่าคะแนน PageRank ไม่ได้สะท้อนถึงความนิยมหรือความโดดเด่นของผลงานโดยตรง นักแสดงที่มีคะแนนสูงมักเป็นนักแสดงที่มีผลงานจำนวนมาก หรือเป็นนักแสดงที่มีการร่วมงานกันกับนักแสดงชื่อดังค่อนข้างมาก ทำให้พวกเขาเป็นเหมือนจุดศูนย์กลางในการเชื่อมโยงไปยังนักแสดงกลุ่มอื่นๆ ดังนั้นคะแนน PageRank จึงสะท้อนถึงอิทธิพลในการเชื่อมโยงนักแสดงได้ดีกว่าพิจารณาเพียงแคความนิยม นอกจากนี้สังเกตจาก Network Graph จะเห็นว่า มีเพียงนักแสดงส่วนน้อยที่มีการเชื่อมโยงจำนวนมาก ขณะที่นักแสดงส่วนใหญ่มีการเชื่อมโยงจำนวนไม่มาก แสดงถึงความไม่สมดุลของอิทธิพลภายในวงการนักแสดง และจาก Bar Chart รวมไปถึง Scatter Plot ที่แสดงถึงการกระจายของคะแนน PageRank ของเครือข่าย ค่าจะมีการลู่เข้าค่าที่มีความเสถียรมากขึ้นเรื่อยๆ

ผลการวิเคราะห์แสดงให้เห็นถึงการนำอัลกอริทึม PageRank สามารถนำไปประยุกต์ใช้ระบุความสัมพันธ์ของบุคคลในเครือข่ายได้จริง และสามารถนำไปประยุกต์เพื่อการศึกษาความเชื่อมโยงแบบมีประสิทธิภาพ

บทที่ 5 สรุปผล

การทำรายงานนี้มีวัตถุประสงค์เพื่อศึกษาการทำงานของอัลกอริทึม PageRank ที่ทำงานร่วมกับการวาร์ป (PageRank with Teleportation) และการประยุกต์ใช้อัลกอริทึมกับเครือข่ายนักแสดงจากข้อมูลของ IMDb เพื่อวัดระดับอิทธิพลและความสำคัญของนักแสดงในเครือข่าย ผลของการดำเนินงานทำให้เข้าใจการคำนวณคะแนน PageRank รวมไปถึงบทบาทของ Teleportation ซึ่งช่วยให้ผลลัพธ์มีความเสถียรมากยิ่งขึ้น เนื่องจากสามารถหลีกเลี่ยงปัญหาต่างๆภายในเครือข่าย โดยเฉพาะ การติดอยู่ในโหนดที่ไม่มีลิงก์ออกได้ หรือ Dead End และ ปัญหาการติดกัมมมม นอกจากนี้ยังช่วยกระจายคะแนนให้โหนดในเครือข่ายให้มีความสมดุล

ผลลัพธ์จากการประยุกต์ใช้กับข้อมูลนักแสดง พบว่า คะแนน PageRank ของนักแสดง 50 อันดับแรกในฐานข้อมูล IMDb รวมกันเท่ากับ 0.07512 และมีค่าเฉลี่ยเท่ากับ 0.0014102 และนักแสดงที่มีคะแนน PageRank สูงที่สุด แสดงถึงอิทธิพลในเครือข่ายที่มากที่สุด ได้แก่ Robert De Niro ซึ่งมีคะแนน PageRank เท่ากับ 0.002896

โดยสามารถสรุปได้ว่า นักแสดงที่มีคะแนน PageRank สูงที่สุดไม่ได้สะท้อนถึงจำนวนผลงานเพียงอย่างเดียว ยังสามารถสะท้อนถึงการร่วมงานกันกับนักแสดงที่มีชื่อเสียงได้อีกด้วย ทั้งนี้ คะแนน PageRank กลับไม่ได้แสดงถึงความนิยมหรือความสำคัญโดยตรง แต่แสดงถึงควมมีอิทธิพล ยังมีคะแนนสูงมาก อิทธิพลที่ส่งผลต่อนักแสดงคนอื่นๆภายในวงการ ก็มีมากขึ้นตามไปด้วย หากต้องการปรับปรุงให้สามารถเพิ่มปัจจัยต่างๆ เช่น ประเภท หรือความนิยมในตอนนั้น อาจจะสามารถสะท้อนความสัมพันธ์ในวงการบันเทิงได้ครอบคลุมมากยิ่งขึ้น

เอกสารอ้างอิง

- [1] Gleich, David F. (2015). PageRank beyond the web. *SIAM Review*, 57(3), 321–363.
<https://www.cs.purdue.edu/homes/dgleich/publications/Gleich%202015%20-%20prbeyond.p>
- [2] Langville, Amy N., & Meyer, Carl D. (2006). *Google's PageRank and beyond: The science of search engine rankings*. Princeton University Press. <https://share.google/eF1vnK3j6UvasZbzq>
- [3] Sergey Brin and Lawrence Page. (1998). The anatomy of a large-scale hypertextual Web search engine. *Computer Networks and ISDN Systems*, 33:107–17,
<https://snap.stanford.edu/class/cs224w-readings/Brin98Anatomy.pdf>
- [4] Sergey Brin, Lawrence Page, R. Motwami, and Terry Winograd. (1999). The PageRank citation ranking: Bringing order to the Web. Technical Report 1999-0120, Computer Science Department, Stanford University. <http://ilpubs.stanford.edu:8090/422/>
- [5] Plaimas, K., Janyasupab, P., Suratanee, A. (2021). Network diffusion with centrality measures to identify disease-related genes. *Mathematical Biosciences and Engineering*, 18(3), 2909–2929.
<https://doi.org/10.3934/mbe.2021147>